Révéler la correspondance cachée entre la Reine Marie-Antoinette et le comte de Fersen : Que peut apporter le deep-learning ?

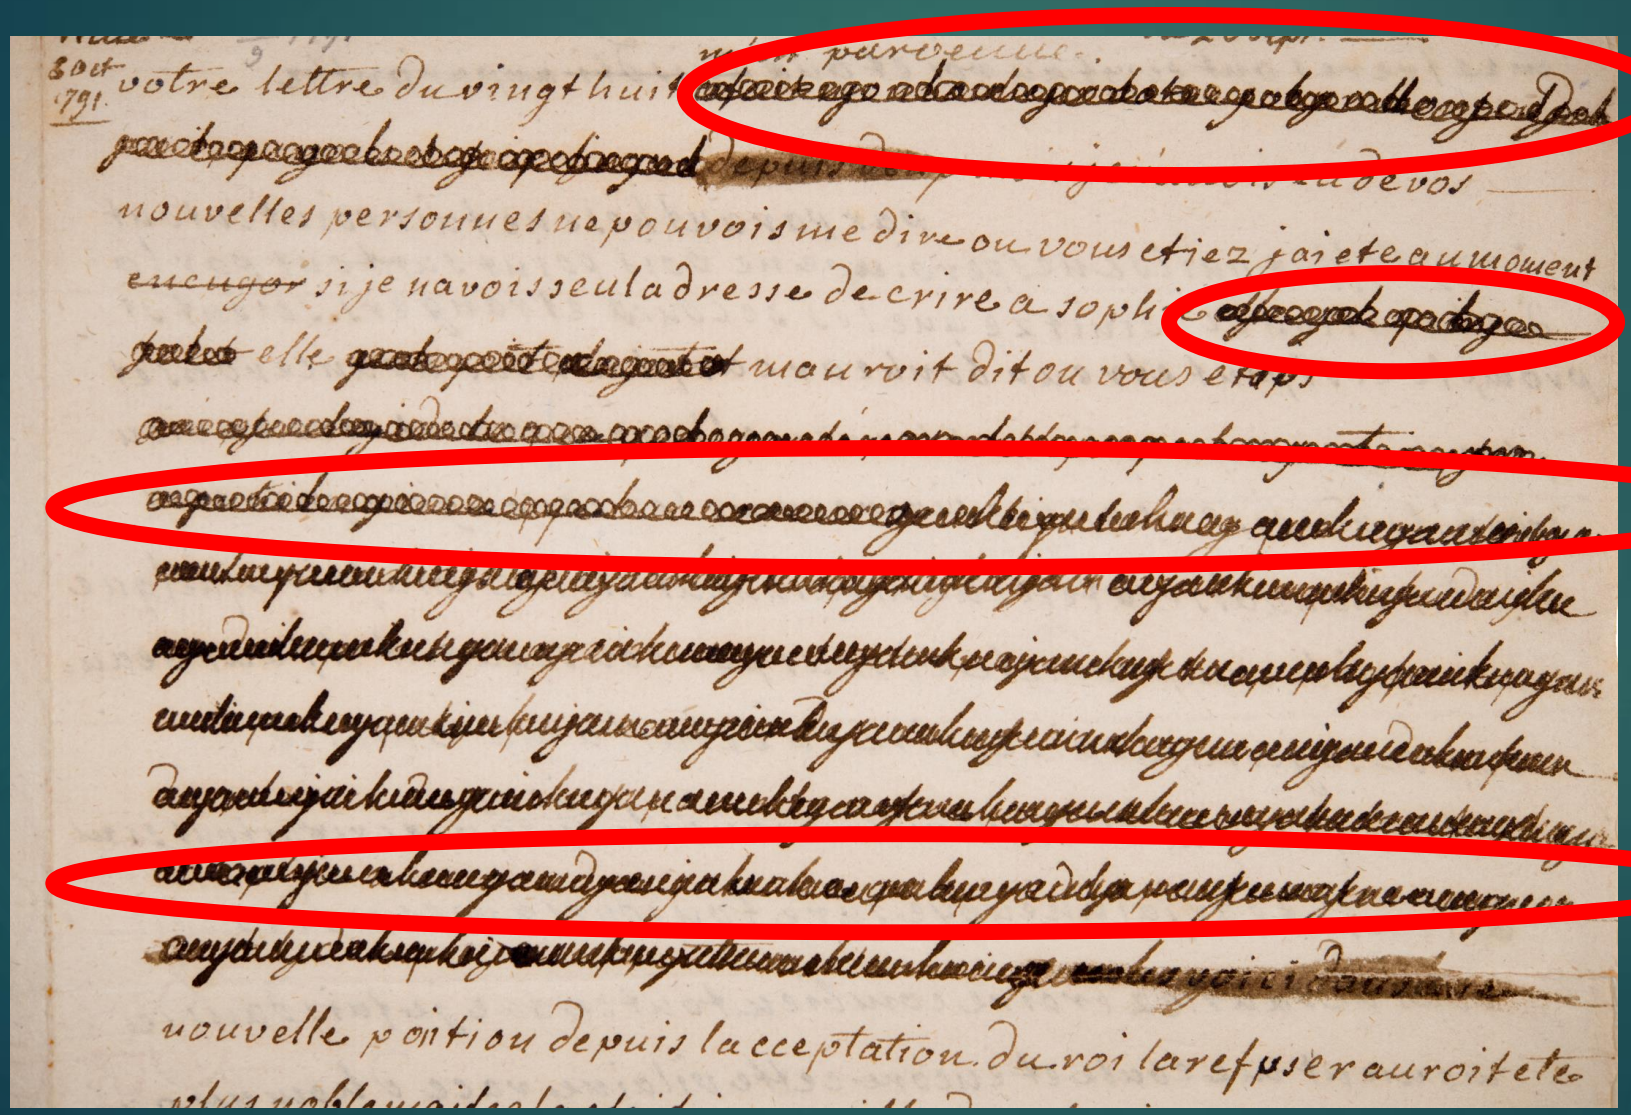
LABORATOIRE XLIM

P. CARRÉ / A. MICHELIN / C. ANDRAUD / P. BONNAUD

Données XRF et séparation de sources

- *Clustering K-means*
- *Analyse en composantes principales et K-means*
- *Analyse en composantes indépendantes et K-means*
- *Décomposition NMF et K-means*
- *Rapport Fer/Cuivre et K-means*
- *CAH, DBSCAN, KernelACP, critère de silhouette et critère d'inertie*

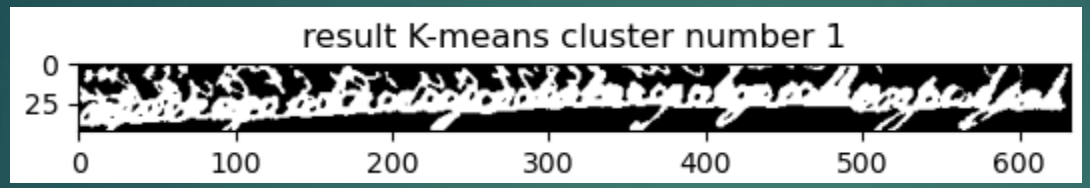
Donnée traitée : lettre 1_1_8

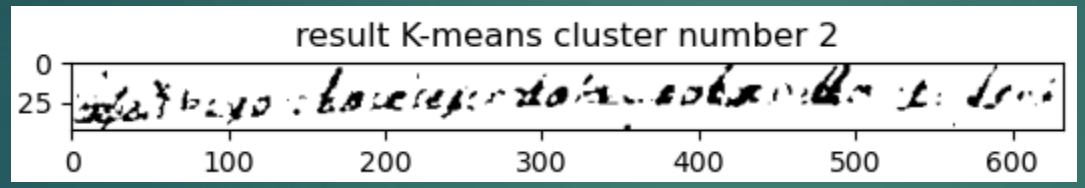


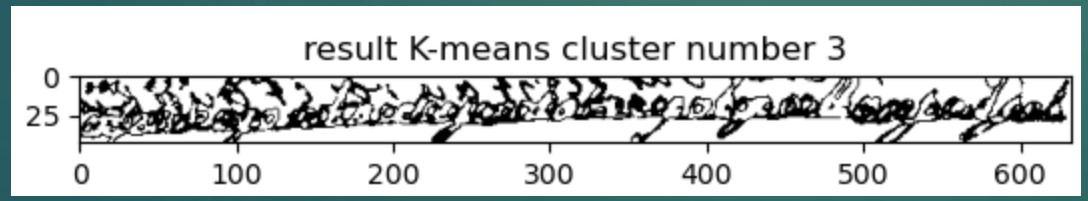
4 lignes traitées :

- *Seul*
- *Ensemble*
- *Partiellement*

K-means







On essaie de séparer les pixels en fonction de leurs spectres

On s'attend à obtenir trois clusters représentant :

- *Le papier*
- *L'encre d'écriture*
- *L'encre de caviardage*

Le clustering est efficient et on a :

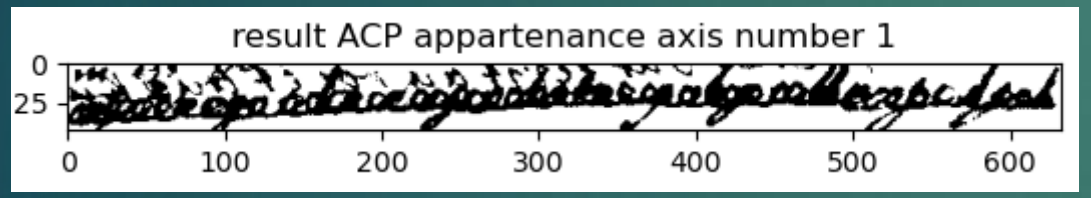
- *Cluster 1 ⇔ papier*
- *Cluster 2 ⇔ encre d'écriture*
- *Cluster 2 ⇔ encre de caviardage*

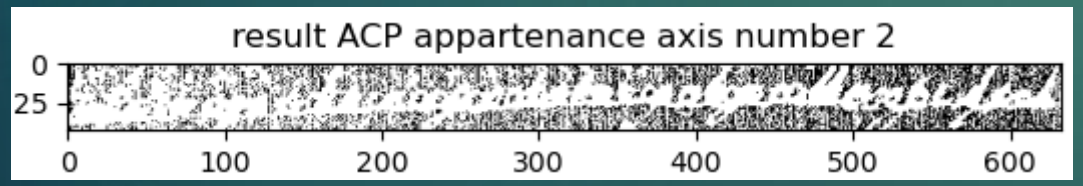
Cependant la présence d'outliers et de bruit perturbe le clustering

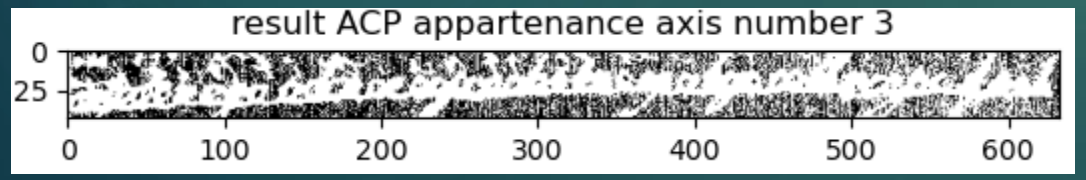
Analyse en composantes principales et K-means

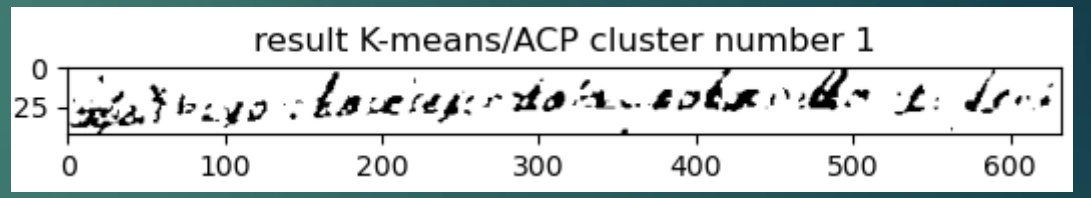


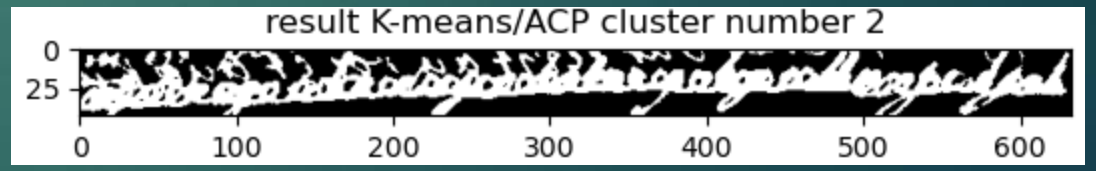
Premier axe de l'ACP utilisé pour le clustering K-means :
L'ACP nous a permis de trouver les axe principaux représentant au mieux notre jeu. Le premier axe représente entre 30 et 50% de notre jeu (selon les lignes traitées). Les axes suivants sont peu représentatif (>2%).

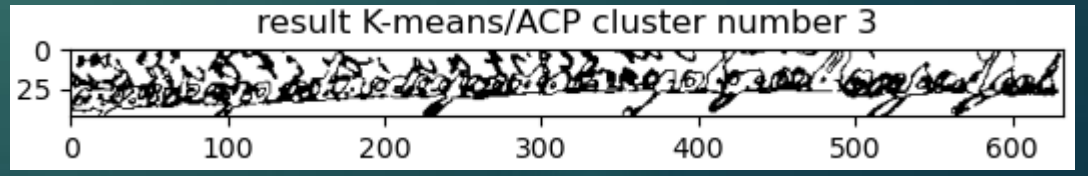






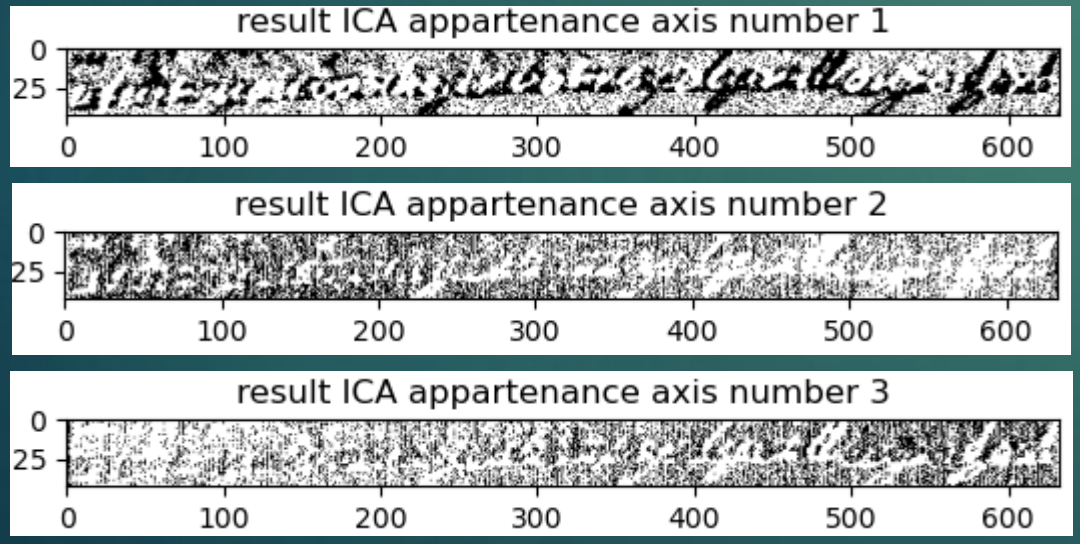




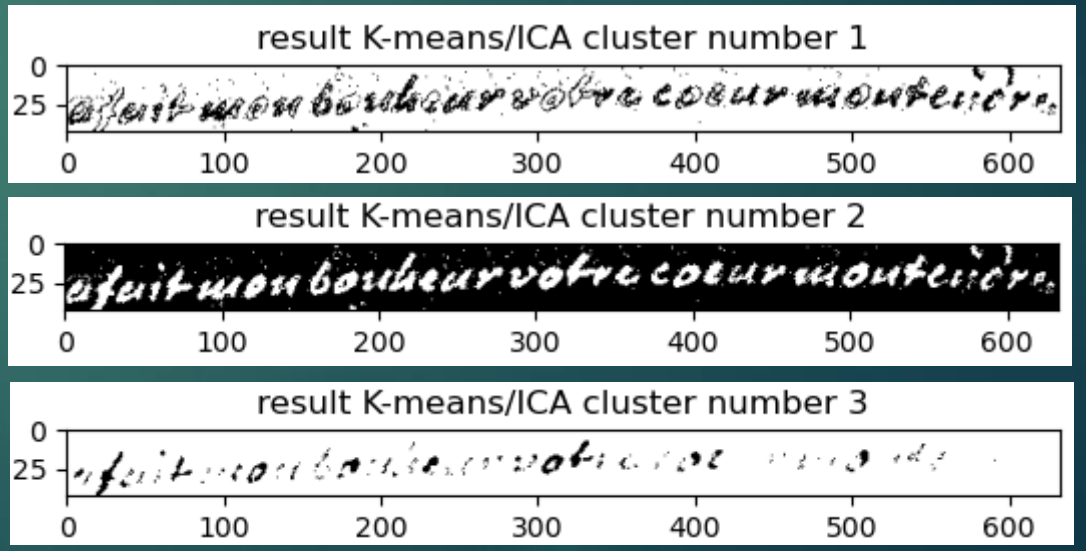


Analyse en composantes indépendantes et K-means

L'ICA est utilisé pour essayer de séparer notre jeu. On considère qu'il existe trois sources différentes et que chaque pixels serait une combinaison linéaire de ces trois sources.

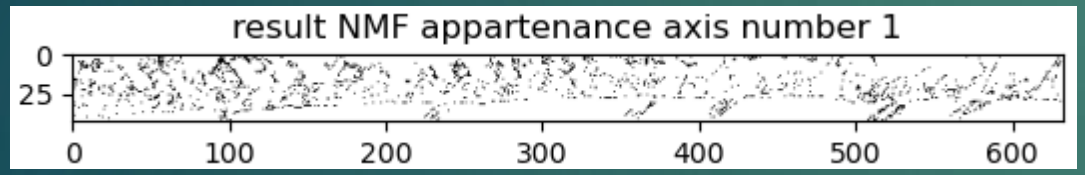


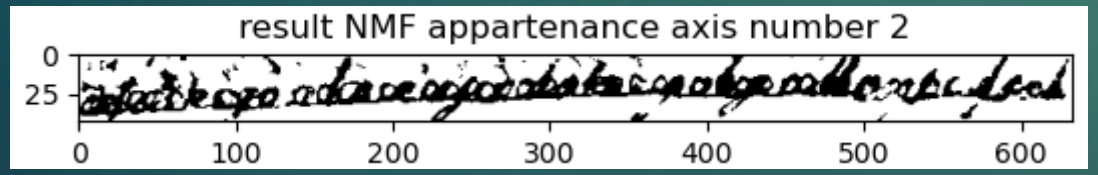
Premier axe de l'ICA utilisé pour le clustering K-means :
On veut éliminer les outliers et le bruit résiduel (peut-être que 2 clusters nous donnerait de meilleur résultats : ici on peut utilisé le critère d'inertie pour définir le nombre de clusters idéal).

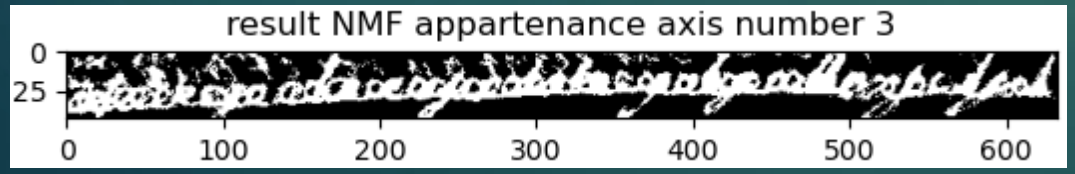


Décomposition NMF et K-means

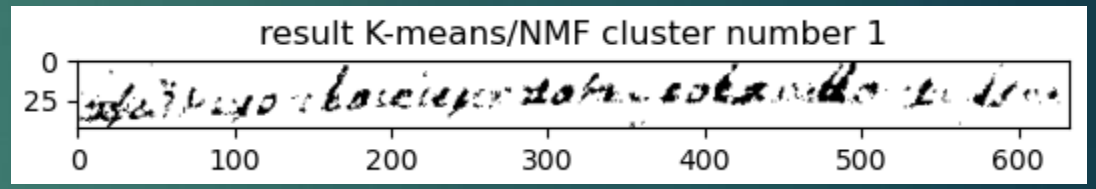


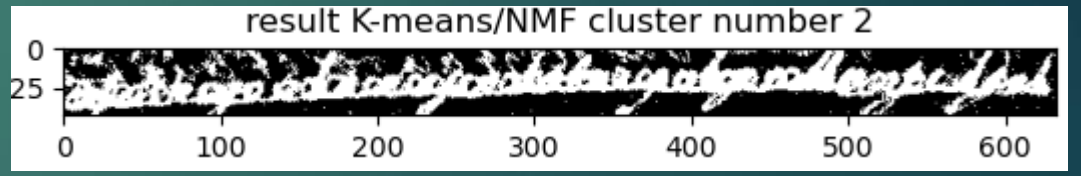


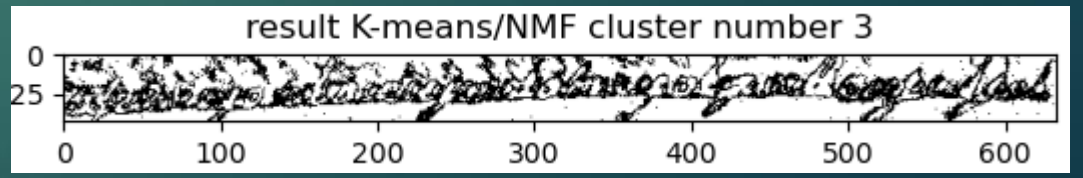




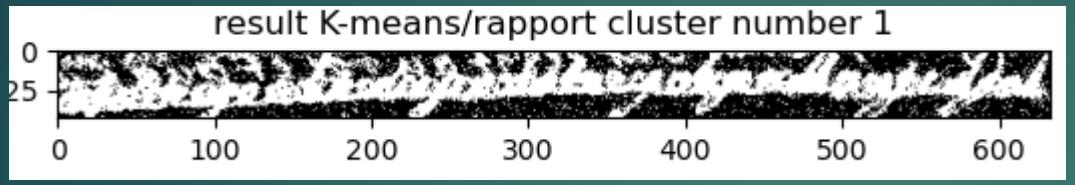
Premier axe de la NMF utilisé pour le clustering K-means

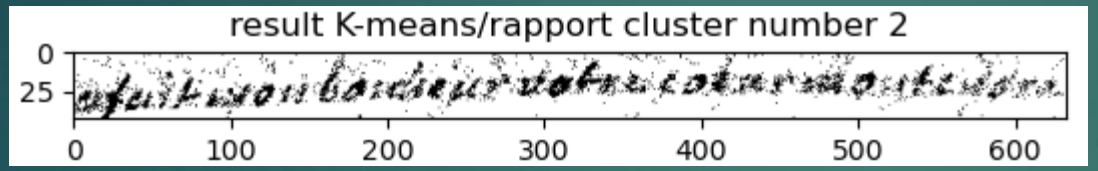


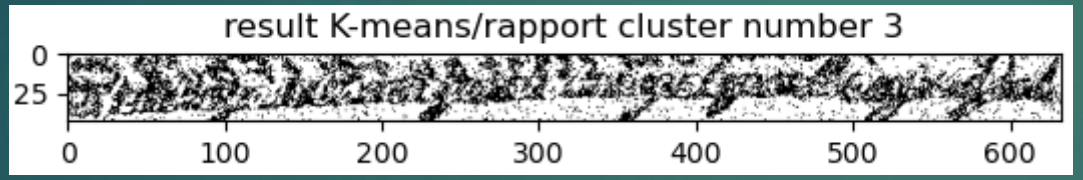




Rapport Fer/Cuivre et K-means







Le rapport Fer/Cuivre permet de réaliser un clustering adéquat.

Cependant ce rapport n'est pas toujours déterminant.

CAH, DBSCAN, KernelACP, critère de silhouette et critère d'inertie

- *CAH et calcul du critère de silhouette trop long*
- *DBSCAN non concluant*
- *KernelACP long au calcul*
- *Critère d'inertie implique un nombre de clusters de 5 ou 6*

Réunir les lignes en un seul jeu ne permet pas une meilleur précision

Séparer les lignes en morceaux ne permet pas de meilleurs résultats (avec K-means)

Problèmes et perspectives pour optimiser la séparation de sources

- *Tous les jeux sont bruités différemment*
- *Aucune méthode ne permet de séparer l'ensemble des lignes*
- *résultats varient avec le spectre pris en compte (ici 0,5 à 13,5 keV)*

- *Machine Learning (nécessite une classe d'apprentissage)*
- *Réseau de neurones à convolution sur les images TIFF :*

1	0	-1
1	0	-1
1	0	-1

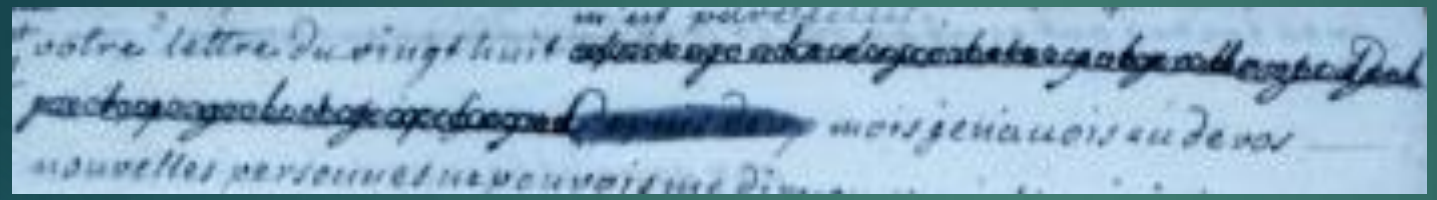
Vertical

1	1	1
0	0	0
-1	-1	-1

Horizontal

Dernière piste : matrice de convolution

original



Après convolution par une matrice dite 'verticale'



On utilise des matrices de convolutions afin de mettre en évidences les interfaces horizontales et verticales.
On espère éliminer un maximum d'encre de caviardage : les motifs de caviardages sont souvent des motifs répétés et qui sont soit très horizontaux soit très verticales.

Conclusion

- *Une multitude de traitement plus ou moins long et complexe possible*
- *Aucun moyen de déterminer au préalable quel sera le traitement le plus efficace*
- *Chaque traitement possède un jeu de paramètre modulable rendant les possibilité toujours plus nombreuses*

- *Le machine learning est peut-être capable de répondre au problème. Cependant nous devons trouver le moyen d'entrainer nos modèles.*