Université de Poitiers
U.F.R Sciences Fondamentales et Appliquées
Master traitement du signal et des images – parcours EUR Smart IoT

Année Universitaire 2021 - 2022

RAPPORT de STAGE

En vue de l'obtention du grade de Master

Développer une nouvelle architecture de réseaux de neurones convolutionnels pour la microscopie optique quantitative

Stage effectué du 28/03/2022 au 30/09/2022



Réalisé par
BONNAUD Peter

Enseignant référent :
HELBERT David

Tuteurs de stage
BON Pierre / MAUCORT Guillaume
Laboratoire LP2N, UMR 5298
Rue François Mitterrand, 33400 Talence

Table des matières

Introduction 5
1. Présentation globale 5
   a. Présentation de la structure d'accueil 5
      i. Le laboratoire 5
      ii. L'équipe-projet et ses travaux 6
   b. Cahier des charges 7
      i. Motivations 7
      ii. Les missions 15
2. Gestion de projet 18
   a. Gestion du temps et organisation projet 18
   b. Anticipation des risques 19
3. Les existants 22
   a. Existant de la mission de prédiction de fluorescence 22
      i. Modèle et pré-traitement 22
      ii. Modèle et couches complexes 24
   b. Existant de la mission de classification 26
4. Résultats et discussions de la mission de prédiction de fluorescence 28
   a. U Net 28
   b. Utilisation de la corrélation de Pearson comme fonction de perte 31
   c. Variation du U Net 33
   d. Utilisation d'un ajusteur automatique de coefficient d'apprentissage 36
   e. Corrélations de Pearson hautes et basses fréquences comme fonction de perte 37
   f. Conclusion et perspectives 38
5. Résultats et discussions de la mission de classification 39
   a. Mise en place d'un CNN 39
   b. Mise en place d'un réseau de neurones linéaire 41
   c. Seconde version du CNN : réseau de neurone hybride 42
   d. Macro-classes et coopérations de modèles 44
   e. Conclusion et perspectives 47
Conclusion 48

Table des figures

Figure 1 : Schéma de fonctionnement d'un microscope de fluorescence 8
Figure 2 : Spectre d'émission et d'absorption d'un fluorophore 8
Figure 3 : Diagramme de Jablonski pour un électron excité pour la microscopie de fluorescence..... 9
Figure 4 : exemple d'acquisition avec un microscope de fluorescence de cellules exprimant de la fluorescence au niveau des mitochondries..... 9
Figure 5 : Illustration du photoblanchiment a l'acquisition pour la microscopie de fluorescence..... 10
Figure 6 : Illustration des problèmes de rapport signal à bruit pour la microscopie de fluorescence . 11
Figure 7 : schéma de fonctionnement d'un microscope électronique 12
Figure 8 : à gauche le schéma de la microscopie à contraste de phase, à droite le fonctionnement d'un masque de Hartmann..... 13
Figure 9 : processus de reconstruction numérique pour les images de phase et d'intensité..... 13
Figure 10 : Supplementary Figure 2 du papier [1]..... 14
Figure 11 : Procédé d'apprentissage et de prédiction du réseau de neurone de la mission de prédiction de fluorescence..... 16
Figure 12 : Schéma simplifié du microscope d'acquisition de la mission de prédiction de fluorescence 16
Figure 13 : Schéma illustrant l'objectif de la mission 2 17
Figure 14 : Suivi de version git pour la mission de prédiction de fluorescence 18
Figure 15 : Panel de données défavorable à l'apprentissage..... 20
Figure 16 : Histogramme image de phase et image d'intensité..... 21
Figure 17 : Quelques exemples de paramétrisation pour un réseau de neurones..... 21
Figure 18 : Schéma de l'architecture U Net 22
Figure 19 : Exemple d'un recalage et d'une déconvolution..... 23
Figure 20 : Recherche numérique du coefficient d'égalisation d'ordre de grandeur intensité/phase optimal 24
Figure 21 : Couche de convolution complexe 25
Figure 22 : Présentation des scénario ReLu complexe..... 26
Figure 23 : Illustration de k-means appliqué sur les variables extraites des images de nanoparticule 27
Figure 24 : Dispersion du jeu de donnée labélisé..... 28
Figure 25 : Diagramme boîte du jeu labélisé..... 28
Figure 26 : Résultats de prédiction de fluorescence de mitochondries avec U Net 29
Figure 27 : superposition de prédiction, de label et d'image d'intensité pour les mitochondries avec le modèle U Net 30
Figure 28 : Résultats de prédiction de fluorescence avec la corrélation de Pearson comme fonction de perte 32
Figure 29 : superposition de label, prédiction et image de phase pour le réticulum endoplasmique avec U Net et Pearson 32
Figure 30 : schéma du M Net 34
Figure 31 : Schéma du Multires U Net 34
Figure 32 : Résultats de prédiction de fluorescence de réticulum endoplasmique avec M Net 35
Figure 33 : Résultats de prédiction de fluorescence de réticulum endoplasmique avec Multires U Net 35
Figure 34 : Fonctionnement de l'ajusteur automatique de coefficient d'apprentissage 36
Figure 35 : Opération pour isoler les basses et hautes fréquences 37
Figure 36 : Résultats de prédiction de fluorescence avec la fonction de perte basses et hautes fréquences (rapport de 10 pour 1 entre hautes et basses fréquences) 37

Figure 37 : Schéma du réseau de neurones convolutionnels 39
Figure 38 : Résultats d'entrainement et de classification pour le CNN 40
Figure 39 : Schéma du réseau de neurones linéaire 41
Figure 40 : Résultats d'entrainement et de classification pour le réseau linéaire 42
Figure 41 : Schéma du réseau de neurone hybride 43
Figure 42 : Résultats d'entrainement et de classification pour l'hybride 43
Figure 43 : Schéma de la coopération de modèles 44
Figure 44 : Résultats pour la coopération (macro-classes) 45
Figure 45 : Résultats pour la coopération (métaux) 45
Figure 46 : Résultats pour la coopération (virus) 46
Figure 47 : Résultats pour la coopération (polymères) 46
Figure 48 : classification par le modèle coopératif sur les jeux de données mixtes 47
Figure 49 : stratification de notre jeu labélisé 48

Table des Annexes

Annexes 1 : Marquage fluorescent 50
Annexes 2 : Gestion du temps, Gantt prévu 51
Annexes 3 : Gestion du temps, Gantt réel 52

Remerciements

Je remercie l'ensemble des personnes qui ont contribué au succès de ce stage. Je remercie également les personnes qui m'ont aidé à réaliser ce rapport de stage.

Tout d'abord j'adresse mes remerciements à mon professeur Mr Clency PERRINE, responsable de la formation Objets Connectés à l'Université de Poitiers. Ainsi que l'ensemble du corps enseignant de la formation qui m'a permis d'avoir les compétences et l'esprit critique nécessaire pour la réalisation de ce stage.

Je remercie Mr Guillaume MAUCORT, actuellement doctorant et travaillant au laboratoire LP2N. Guillaume m'a accompagné durant la totalité du stage et a permis de renforcer ma compréhension des concepts abordés.

Je remercie également Mr Pierre BON, chercheur CNRS pour le laboratoire XLIM, anciennement chercheur pour le laboratoire LP2N. Tout comme Guillaume, Pierre a fortement contribué au développement de mes compétences durant ce stage. Il forçait mon esprit critique avec de nouvelles réflexions et de nouvelles interrogations durant chaque discussion. Je le remercie lui et son équipe.

Je remercie également BOYREAU Adeline, ingénieur biologiste pour le laboratoire LP2N. Adeline m'a formé durant mon stage pour la continuité de celui-ci.

Enfin je tiens à remercier mon enseignant référant Mr HELBERT David, professeur à l'Université de Poitiers, pour le suivi de mon stage.

Introduction

Avec les progrès dans les sciences notre compréhension du monde évolue rapidement. Une des clés principales de compréhension réside dans notre capacité à observer pour interpréter et déduire. Du physicien au chimiste, les règles et les lois de notre monde ont été acquises puis démontrées grâce à des phénomènes observables.

De nombreuses disciplines reposent sur cette capacité à observer et améliorer notre capacité d'observation implique donc d'améliorer l'état de nos connaissances. Parmi les disciplines les plus impactées par cette capacité, nous retrouvons la médecine et la biologie. Ces deux disciplines permettent de réaliser une étude du vivant. Quand l'une tente de diagnostiquer l'autre tend à expliquer. Cependant les études biologiques et médicales sont aujourd'hui soumises à de fortes contraintes.

La microscopie photonique ou électronique permet d'observer la matière à différentes échelles microscopique et plus récemment nanoscopique. Vous pouvez faire appel au photon ou à l'électron. Avec le photon vous pourrez réaliser une observation soit précise, ciblée et invasive soit une observation générale, non ciblée et non invasive. Avec l'électron vous pourrez réaliser une observation précise mais aussi invasive et lente.

Une question se démarque alors de ces contraintes : existe-t-il une méthode non invasive, précise et ciblée pour observer le monde cellulaire sans compromettre la quantité d'informations extractibles ?

Dans ce rapport une méthode sera présentée pour réaliser une observation cellulaire non invasive, ciblée et avec une précision proche des techniques d'observations actuelles. Cette étude est motivée par les récentes publications [1] et [2]. Une étude sur la classification de nanoparticules sera aussi présentée dans ce rapport, cette seconde étude est motivée par le besoin direct d'un procédé de classification de nanoparticules inconnues.

1. Présentation globale

a. Présentation de la structure d'accueil

i. Le laboratoire

Pour ce stage, la structure d'accueil est le laboratoire de photonique, nanoscience et numérique (LP2N) à Bordeaux. Ce laboratoire est hébergé au sein de l'Institut d'Optique d'Aquitaine qui accueille divers acteurs tel qu'une école d'ingénieurs, des entreprises, la CRT Alphanov, …

Le laboratoire LP2N est reconnu pour ses travaux dans les domaines de l'optique appliquée et plus récemment dans les domaines de la biophysique avec le développement de la *Cellular Capsule Technology*, technique révolutionnant la mise en culture des cellules-souches et lauréate d'une médaille de l'innovation décernée par le CNRS. 8 équipes sont membres de ce laboratoire :

- Nanophotonique, cette équipe vise à comprendre, maîtriser et exploiter les interactions lumière-matière à l'échelle du nanomètre. À cette fin, le groupe développe des techniques de microscopie optique ultra-sensible pour la détection d'objets à l'échelle nanométrique

et explore des applications révolutionnaires en optique quantique, en physique de la matière condensée et en biophotonique.

- Lumières dans les milieux complexes, cette équipe étudie les propriétés de systèmes cohérents impliquant une diffusion multiple et forte de la lumière avec un individu ou un ensemble de nano-objets quantiques ou classiques ou les deux.
- Atomes froids à Bordeaux, dédiée à l'utilisation des ondes atomiques, soit pour exploiter la sensibilité inégalée des interféromètres à ondes de matière, soit pour développer des simulateurs quantiques où les atomes sont utilisés pour étudier les propriétés de transport et de propagation dans des potentiels exotiques.
- Bioimagerie et optofluidique, équipe qui a récemment développé une technique assistée par microfluide, la *Cellular Capsule Technology* (CCT) qui permet d'encapsuler des cellules et de faire croître des organoïdes ou des modèles tumoraux dans une enveloppe d'hydrogel poreux.
- NanoBioMicroscopy, équipe dont les travaux sont liés aux domaines généraux du suivi de particules uniques, de la microscopie à super-résolution, de l'imagerie de phase quantitative et de la spectroscopie de nanostructures 1D.
- Infographie et optique computationnelle, équipe spécialisée dans les thématiques d'optique computationnelle et d'infographie.
- Imagerie computationnelle et affichage, équipe spécialisée dans l'imagerie computationnelle.
- Systèmes photoniques, équipe spécialisée dans le développement de nouveaux systèmes photoniques.

ii. L'équipe-projet et ses travaux

Ce stage se déroule dans l'équipe NanoBioMicroscopy. Cette équipe se focalise sur les thématiques des nanosciences, de l'optique et de la bio-imagerie pour concevoir et étudier des nanostructures synthétiques innovantes et pour investiguer des systèmes biologiques complexes à l'échelle nanométrique. Cette équipe est lauréate de 2 bourses ERC pour ses projets d'imagerie non invasive et d'imagerie cérébrale.

L'équipe est divisée en trois équipes-projet animé par 3 chercheurs du CNRS :

- Etienne GAUFRES
- Laurent COGNET
- Pierre BON

Ce stage se déroule dans l'équipe-projet animée par Pierre BON, dont l'activité de recherche vise à développer des techniques d'imagerie optique non-invasives et quantitatives capable d'étudier le vivant à des échelles sub-cellulaire. Cette équipe-projet est constituée des membres suivants :

- Alberto AGUILAR-MORA — Ingénieur optique travaillant sur la thématique de super résolution en microscopie,
- Adeline BOYREAU — l'ingénieur biologiste de l'équipe NanoBioMicroscopy,
- Guillaume MAUCORT — Doctorant sur la thématique de deep learning appliqué à la microscopie cellulaire,
- Minh-Chau NGUYEN — Postdoctorant travaillant sur la thématique de propagation numérique et de tracking.

Le mode opératoire de l'équipe-projet repose sur un principe de co-conception : chaque membre de l'équipe a en charge une thématique différente et complémentaire avec les thématiques des autres membres. À long terme chaque travail servira le projet final : une meilleure résolution pour une acquisition plus fine, une propagation numérique pour le suivi des entités à acquérir dans un volume et une architecture d'apprentissage automatique pour répondre aux problématiques de prédiction de fluorescence. Aussi les projets ne sont pas cloisonnés les uns par rapport aux autres et de nombreuses avancés sont adaptables ou réutilisables. La cohésion et le partage font que chaque membre de l'équipe a une idée assez précise du champ opératoire des autres membres.

b. Cahier des charges

i. Motivations

Pour étudier un échantillon vivant comme un tissu ou une lignée de cellules, les biologistes ont recours à des méthodes de microscopie spécifiques : s'ils souhaitent mettre en évidence certaines protéines ou certains comportements à une échelle nanométrique, ils doivent recourir aux méthodes de microscopie de fluorescence ou aux méthodes de microscopie électronique. Il existe plusieurs variantes de ces deux méthodes cependant le procédé global est le même d'une variante à l'autre.

1. Microscopie de fluorescence

Pour la microscopie de fluorescence, le principe de fonctionnement consiste à utiliser un marqueur fluorescent synthétisé par l'échantillon, suite à une modification génétique permanente ou non, pour être mis en évidence lors de l'observation : le marqueur est appelé fluorophore. Nous retrouvons en **Annexe 1 : Marquage fluorescent**, le procédé de synthèse des marqueurs fluorescent et le procédé de marquage des échantillons biologiques.

D'un point de vue technique la microscopie de fluorescence est une microscopie pouvant être invasive et qui présente des rapports signaux sur bruits plutôt faibles. L'éclairage des échantillons nécessite une source de forte brillance (laser, …) dont la longueur d'onde est courte pour une fluorescence dans le visible, ce qui peut s'avérer nocif (phototoxicité) pour les échantillons. Cependant cette microscopie présente deux avantages techniques considérables, la fluorescence des échantillons est une émission isotrope (en réalité la fluorescence est considéré comme incohérente, c'est-à-dire que les photons observés sont indépendant est différent des photons d'excitation) rendant l'impact des angles d'incidence d'observation et d'excitation négligeable et la réflexion du laser d'excitation peut être totalement supprimée (par des filtres colorés comme nous allons le discuter plus loin) ce qui permet une imagerie sur fond noir. Afin de simplifier l'imagerie et la préparation des échantillon, il est choisi que cette microscopie soit en épifluorescence c'est-à-dire que l'échantillon est éclairé par le dessus et que l'observation est une observation par réflexion. Un miroir dichroïque assure alors la séparation des chemins optiques d'excitation et de réflexion. L'aspect isotrope permet ce type de fonctionnement et la faible réflexion du laser d'excitation permet de rehausser le signal utile par rapport au signal parasite de la source d'excitation. En **Figure 1** nous retrouvons un schéma descriptif d'un microscope de fluorescence. Un filtre d'excitation permet de sélectionner uniquement la longueur d'onde adéquate pour l'excitation, le filtre barrière permet au microscope de se désensibiliser des sources lumineuses externes : l'acquisition doit cependant être réalisée dans le noir à la vue des faibles niveaux de signaux de fluorescence.

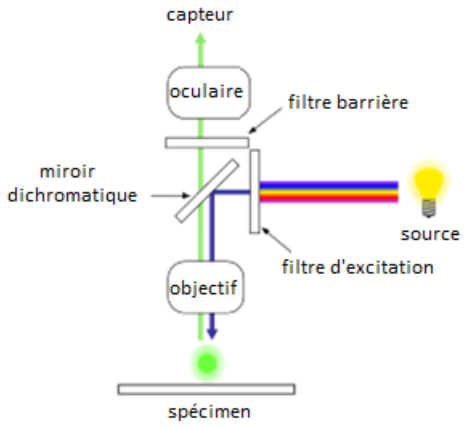


Figure 1 : Schéma de fonctionnement d'un microscope de fluorescence

Un point très important du fonctionnement de la microscopie de fluorescence concerne les fluorophores. Pour pouvoir séparer les chemins optiques d'excitation et de réflexion il faut que ces chemins présentent des longueurs d'onde différentes : le miroir dichromatique permet de réfléchir une plage de longueur d'onde donnée, d'en laisser passer une autre et d'absorber le reste. Cette variation de longueurs d'onde est assurée par le comportement des fluorophores : le spectre d'absorption d'un fluorophore est différent de son spectre d'émission. En **Figure 2** nous retrouvons un graphe illustrant les spectres d'émission et d'excitation pour un fluorophore donné. Nous constatons que la longueur d'onde d'excitation est plus courte que la longueur d'onde d'émission : la différence entre ces deux longueurs d'onde est caractérisée par le « déplacement de Stokes » dépendant du fluorophore utilisé.

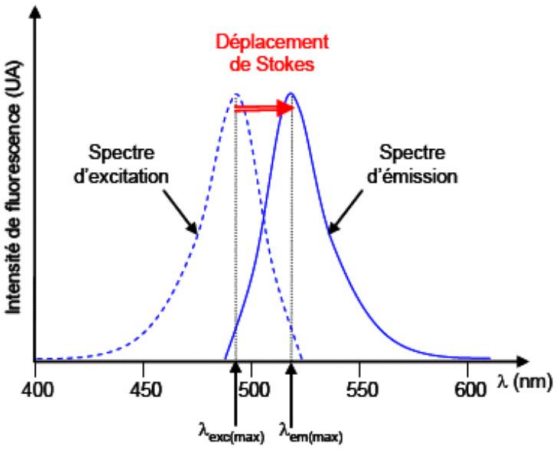


Figure 2 : Spectre d'émission et d'absorption d'un fluorophore

Puisque la longueur d'onde d'émission est plus courte que la longueur d'onde d'absorption, cela signifie que l'énergie émise est plus faible que l'énergie absorbée. Il existe donc une perte d'énergie entre l'émission et l'absorption. La **Figure 3** présente un diagramme de Jablonski qui explique cette perte d'énergie. Cette perte est une dissipation d'énergie non-radiative : une fois excitée les électrons des molécules fluorescentes, alors sur des couches électroniques plus lointaine du noyau,

perdent une partie de l'énergie d'excitation dû à leurs activités (oscillations, vibrations, radiations, interactions électroniques), créant de temps en temps des radicaux libres (espèce chimique possédant un ou plusieurs électrons non appariés sur sa couche externe).

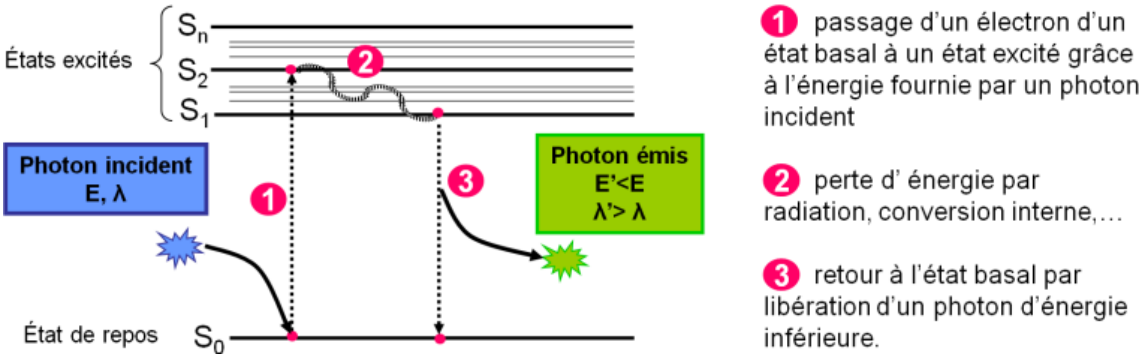


Figure 3 : Diagramme de Jablonski pour un électron excité pour la microscopie de fluorescence

La microscopie de fluorescence permet donc de révéler uniquement les composants qui ont été marqués (ex. comme les mitochondries, usine énergétique d'une cellule). En **Figure 4** on retrouve un exemple de fluorescence sur des cellules pour mettre en évidence leurs mitochondries. Le marqueur utilisé fluoresce dans le vert.

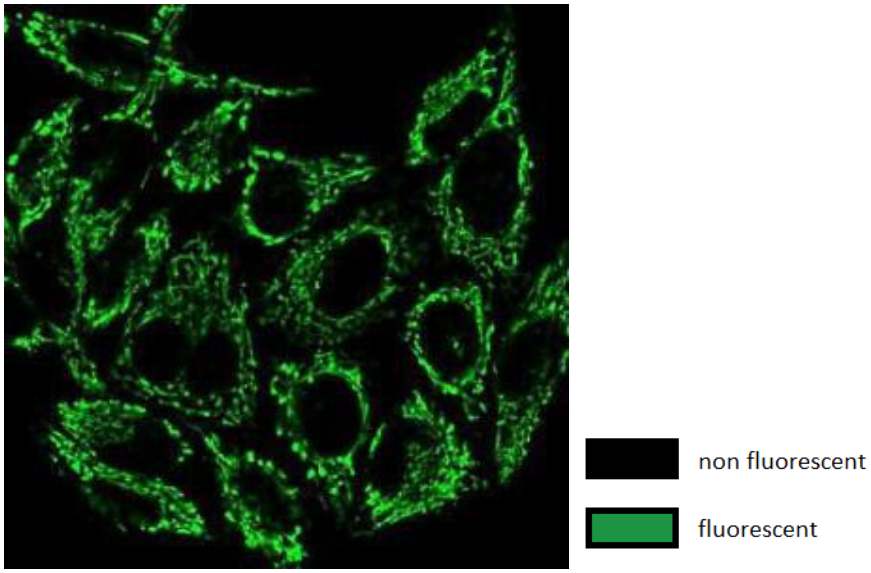


Figure 4 : exemple d'acquisition avec un microscope de fluorescence de cellules exprimant de la fluorescence au niveau des mitochondries

Si les acquisitions permettent de révéler certains composants des échantillons, il reste un point important à prendre en compte : les acquisitions sont en 2D alors que l'information observée est un volume, de nombreuses problématiques de convolution apparaissent. Une évolution de ce type de microscopie est la microscopie de fluorescence confocale. Cette microscopie permet alors de filtrer l'acquisition en profondeur pour ne garder que la tranche souhaitée. Le microscope intègre alors une nouvelle pièce : un sténopé soit un trou circulaire de faible diamètre dans une plaque de faible épaisseur.

Classique ou confocale, la microscopie de fluorescence présente un certain nombre de désavantages à l'acquisition et pour l'échantillon étudié : photoblanchiment, phototoxicité, modification génétique (ou ajout exogène de matière : parfois le marqueur fluorescent n'est pas synthétisé par l'échantillon mais ajouté à ce dernier), …

Le photoblanchiment est liée à la photosensibilité des fluorophores utilisés. Plus un échantillon fluorescent est observé longtemps plus son niveau de signal décroit : le faisceau d'excitation fini par détruire le fluorophore, rendant l'observation de plus en plus difficile au cours du temps. Avec ce phénomène, le biologiste doit prendre en considération le facteur temps lors d'une observation. Sur la **Figure 5**, on remarque l'impact du photoblanchiment : au fil du temps la fluorescence faiblit rendant l'acquisition moins précise. Au départ l'énergie émise par la fluorescence est suffisante pour être distingué. Après 29 minutes d'observation avec une image toutes les 30 secondes, on constate qu'une partie de la fluorescence n'est plus distinguable et un bruit poivre et sel apparaît (appelé bruit de photons). La présence du bruit de photons, présentant une distribution de Poisson, est la conséquence d'une réduction de l'intensité du signal (intensité de la fluorescence).

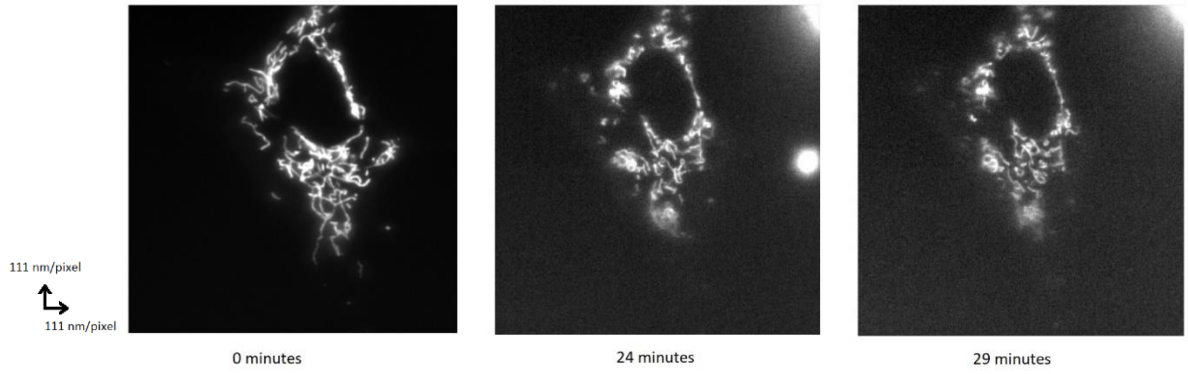


Figure 5 : Illustration du photoblanchiment a l'acquisition pour la microscopie de fluorescence

La phototoxicité est liée à la photosensibilité des échantillons biologiques. L'utilisation prolongée d'une excitation de forte puissance sur l'échantillon finit par le dégrader. La création de radicaux libres participe aussi à ce phénomène de phototoxicité en créant des échauffements localisés.

En plus du photoblanchiment et de la phototoxicité, nous devons prendre en compte le comportement biologique. Chaque matériel biologique répond de façon différente au marquage fluorescent (résistances virales différentes, une certaine capacité à intégrer ou synthétiser le fluorophore). Ainsi on peut observer une variabilité entre cellules. Sur la **Figure 6**, on observe une acquisition fluorescente avec un rapport signal à bruit peu propice pour l'étude. Ces rapports signal à bruit faibles sont la conséquence d'un signal émit de faible intensité. Ici le photoblanchiment n'est pas responsable, le spectre d'émission du fluorophore et le taux d'infection de la cellule sont les acteurs

majoritaires de ce rapport signal à bruit. Les fluorophores ont des spectres d'émissions dont la plage de longueur d'onde est plus grande que la plage de leur spectre d'absorption, par conséquent l'énergie émise est inférieure à l'énergie absorbée. On doit ajouter à ce phénomène, le taux d'expression du matériel fluorescent qui est variable et peut être insuffisant.

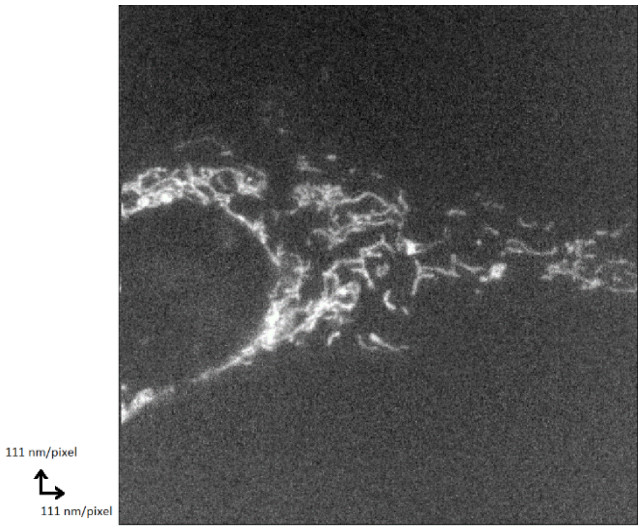


Figure 6 : Illustration des problèmes de rapport signal à bruit pour la microscopie de fluorescence

La mutation des échantillons biologique est une composante obligatoire pour la microscopie de fluorescence. En effet faire synthétiser à l'échantillon des molécules fluorescentes n'est possible que par l'intermédiaire de mutations génétiques. Ces mutations peuvent entrainer un changement de comportement de l'échantillon. Modification de la division cellulaire, production anormale de certains composants, sénescence accrue, … sont des comportements inductibles par la mutation. Le marquage exogène est moins stable dans le temps et s'utilise souvent sur échantillons fixés (c'est-à-dire des cellules mortes figées à un moment donné de leur vie).

2. *Microscopie électronique*

Pour la microscopie électronique aucun fluorophore n'est nécessaire, le principe consiste à bombarder l'échantillon avec un faisceau d'électrons. L'interaction électron-échantillon modifie le faisceau. Les électrons modifiés finissent par être capté grâce à un système d'électroaimant et une plaque électrosensible. L'avantage de la microscopie électronique par rapport à la microscopie photonique, comme la microscopie de fluorescence, est la résolution : la longueur d'onde d'un faisceau d'électron est beaucoup plus petite que la longueur d'onde d'un faisceau photonique. Cependant cette microscopie présente aussi des désavantages considérables concernant ses conditions d'acquisition. Les acquisitions de microscope électronique sont des acquisitions particulièrement lentes qui nécessitent d'être sous vide partiel. Lente car l'ensemble de l'échantillon doit être suffisamment bombardé et sous vide partiel pour éviter des phénomènes de surbrillance liés à une faible conductivité électrique des échantillons et/ou des supports : avec la faible conductivité les électrons stagnent en surface.

La microscopie électronique présente aussi des inconvénients pour l'échantillon étudié, comme pour la microscopie de fluorescence, l'échantillon doit être fixé ce qui signifie la mort du matériel biologique vivant. Une fois fixé il faut trancher l'échantillon pour l'imager. Aussi maintenir une fluorescence en microscopie électronique n'est pas aisé à cause des conditions d'acquisition. En **Figure 7** nous observons le schéma d'un microscope électronique, les lentilles magnétiques correspondent aux électro-aimants, elles permettent de diriger le faisceau d'électrons, le plan image correspond à la position de la plaque électrosensible.

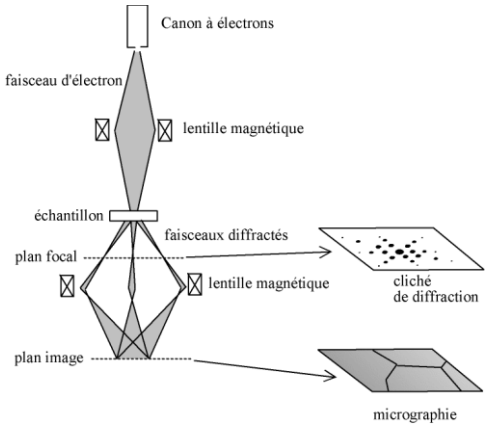


Figure 7 : schéma de fonctionnement d'un microscope électronique

Ces deux techniques de microscopie sont des techniques dites invasives, elles modifient l'échantillon à observer : mort, modification génétique, dégradations, … Il existe des microscopies non invasives, parmi lesquelles se trouve la microscopie à contraste de phase.

3. *Microscopie de phase quantitative*

Le principe de la microscopie de phase est simple : on ne mesure non pas uniquement la quantité de photons mais également le retard entre les photons (appelé également déphasage ou front d'onde). En passant au travers de l'échantillon, l'onde lumineuse se voit en effet ralentir de manière locale dépendamment des interactions avec la matière. Ainsi après le passage de l'onde uniforme dans l'échantillon, l'onde résultante est une onde dont l'intensité et le front d'onde sont caractéristiques de la matière traversée. Un masque de Hartmann modifié (voir publication [3]) permet alors de capturer les déformations de notre onde : des interférences lumineuses viennent encoder notre front d'onde local (et notre intensité) sur des macros-pixels, on observe une modulation de la période des interférences en fonction de la courbure (plus précisément du gradient spatial) du front d'onde. Comparée à la microscopie de fluorescence, la microscopie à contraste de phase ne permet pas de mettre en évidence de façon directe certains composants biologiques : elle contraste tous les éléments présentant des chocs d'indice de réfraction. En **Figure 8** on observe le schéma de fonctionnement de la microscopie de phase quantitative. Le masque de Hartmann est un masque 2D constitué de trous présentant un déphasage en échiquier. Le masque est placé à une certaine distance du capteur de telle sorte que l'onde lumineuse entre en interférence avec elle-même créant des interférences destructives et constructives.

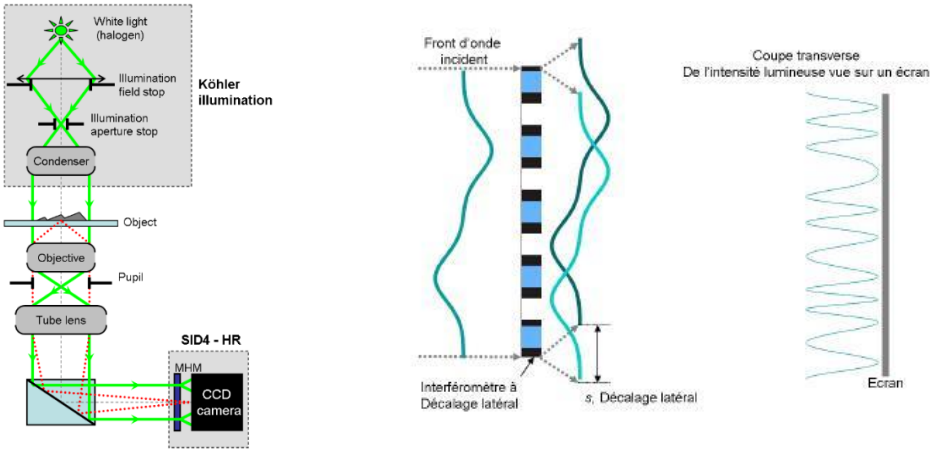


Figure 8 : à gauche le schéma de la microscopie à contraste de phase, à droite le fonctionnement d'un masque de Hartmann

Une fois l'acquisition réalisée, un traitement numérique est nécessaire afin de la rendre exploitable. En **Figure 9** on retrouve la chaîne de traitement numérique utilisée : l'image acquise (appelée interférogramme), subit une transformée de Fourier numérique qui nous permet d'isoler l'intensité et les gradients de déformations. Après la transformée de Fourier, on identifie 9 positions de référence : la position du centre et l'information autour de cette position correspond à l'intensité de notre front d'onde, les 8 autres positions correspondent aux différents gradients de déformations de notre front d'onde. Pour reconstituer l'image d'intensité il nous suffit donc de réaliser une transformée de Fourier inverse pour l'information autour de la position centrale. Pour reconstituer l'image de phase, on choisit deux positions de référence : une pour le gradient de déformation x et une autre pour le gradient de déformation y, après une intégration nous sommes capables de reconstituer l'image de phase. Le choix de deux positions de références permet de maximiser la quantité d'informations pour la reconstruction, choisir deux positions miroirs ne ferait qu'ajouter de la redondance et choisir une position diagonale peut permettre d'augmenter légèrement la sensibilité au prix d'une plus grande complexité de traitement (les gradients diagonaux correspondent à $\pm\frac{1}{2}gradient\ x \pm \frac{1}{2}gradient\ y$).

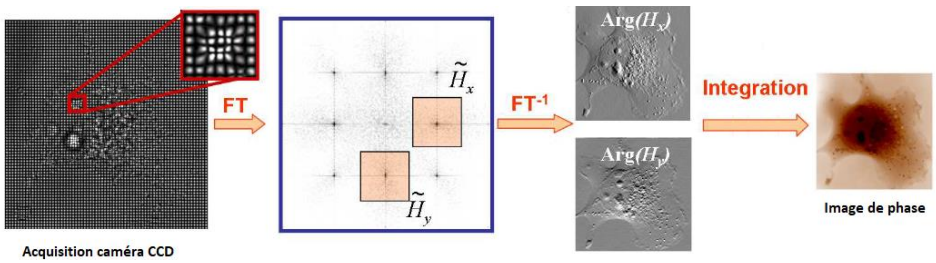


Figure 9 : processus de reconstruction numérique pour les images de phase et d'intensité

4. Conclusion

L'ensemble des désavantages des différentes techniques d'imagerie nous mène à la problématique de l'introduction : peut-on trouver une nouvelle méthode d'observation abordable et libre de toute utilisation de marqueurs fluorescent ? L'existence d'une telle méthode permettrait aux biologistes, une étude plus juste et non invasive des matériaux biologiques.

Dans la publication [1], l'utilisation d'un réseau de neurones permet de prédire une image de fluorescence à partir d'une image de microscopie classique (voir **Figure 10**). Ce résultat prometteur tend à valider l'existence d'une méthode d'observation non-invasive. Nous retrouvons un résultat similaire dans la publication [2] où des images de fluorescence sont prédites par un réseau de neurones. Dans ces deux papiers la méthode est similaire : un réseau de neurones est entraîné à réaliser des prédictions de fluorescence à partir d'image de microscopie classique ou de microscopie à contraste de phase, en utilisant les images de fluorescence réelles comme label. Une prédiction de fluorescence sur des individus non mutés devient alors possible et une observation non invasive est réalisable. La **Figure 10**, nous présente un ensemble de prédiction de fluorescence d'images de microscopie électronique. Les résultats de prédiction de fluorescence confirme qu'un réseau de neurones peut retrouver de l'information issue de microscopie de fluorescence à partir d'une microscopie tierce.

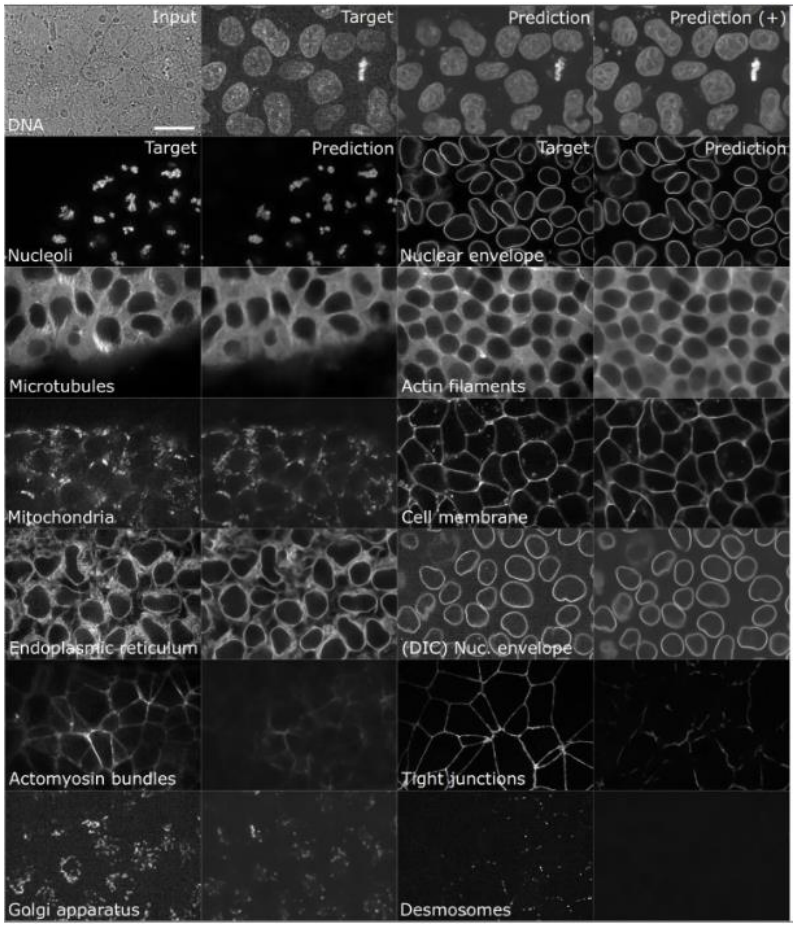


Figure 10 : Supplementary Figure 2 du papier [1]

L'équipe projet a donc entrepris de prédire des images de fluorescence. La microscopie non invasive choisie est la microscopie de phase quantitative. La stratégie de l'équipe-projet est donc de mettre en place un réseau de neurones afin d'extraire de l'information d'image de phase pour reproduire les images de fluorescence.

ii. Les missions

Deux missions me sont confiées au sein de cette équipe : la première mission qui revêt un aspect prioritaire concerne la prédiction de fluorescence des images à contraste de phase pour prédire les images de fluorescence, la seconde mission est une mission de classification dans laquelle une prédiction de la nature de plusieurs nanoparticules m'est demandée.

1. Mission de prédiction de fluorescence

Pour la première mission, une architecture deep est actuellement en place, cette architecture est un réseau de neurones de type U_Net. L'existant de la première mission offre des résultats variables, allant d'une prédiction de fluorescence quasiment parfaite à une prédiction de fluorescence moins fine. Mon objectif dans cette première mission est d'optimiser l'architecture présente ainsi que la mise en place et le test de nouvelles architectures. L'acquisition des données n'est pas à ma charge, le pré-traitement des données n'est pas à ma charge, les données sont constituées d'images d'intensité et de phase ainsi que de document texte référençant la qualité de l'acquisition. Les images se présentent sous la forme de tableaux hexadécimaux avec une entête de deux octets codant la taille de l'image finale, les valeurs des pixels des images sont codées en 32 bits réels. Pour l'entrainement des modèles, les images sont décomposées en plusieurs patchs choisis aléatoirement dans l'image et de telle sorte que chaque pixel des images initiales soit contenu dans le jeu de patch au moins une fois. Le pré-traitement des données correspond à un recadrage pour aligner l'acquisition fluorescente avec l'acquisition à contraste de phase, ainsi qu'une déconvolution de l'image de fluorescence acquise en 3D (si le traitement 3D est considéré). La **Figure 11** illustre le procédé d'entrainement et de prédiction pour le réseau de neurones de la mission 1 sur acquisitions 2D (ne présentant donc pas de déconvolution de la fluorescence).

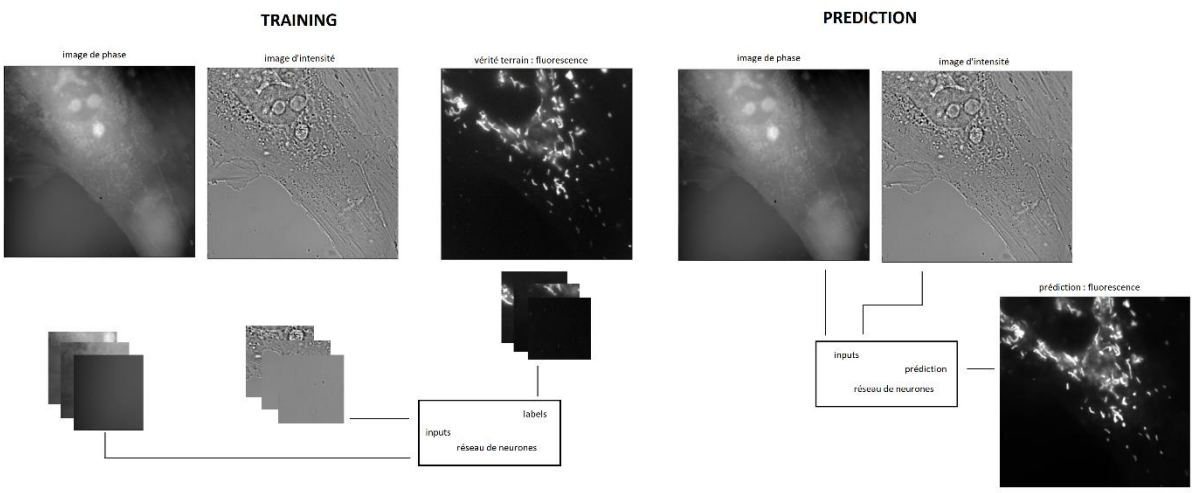


Figure 11 : Procédé d'apprentissage et de prédiction du réseau de neurone de la mission de prédiction de fluorescence

Le matériel d'acquisition est un microscope capable de réaliser une acquisition de phase et de fluorescence simultanément, composé de deux sources lumineuses : une lumière blanche en transillumination et un laser d'excitation pour la fluorescence en épifluorescence. Un jeu de miroirs dichromatiques permet d'isoler les deux acquisitions, deux caméras sont prévues pour collecter les images de fluorescences et de contraste de phase : les caméras étant spatialement séparées, il existe un temps d'environ 200 microsecondes entre les deux acquisitions. La **Figure 12** est un schéma simplifié du microscope utilisé pour les différentes acquisitions.

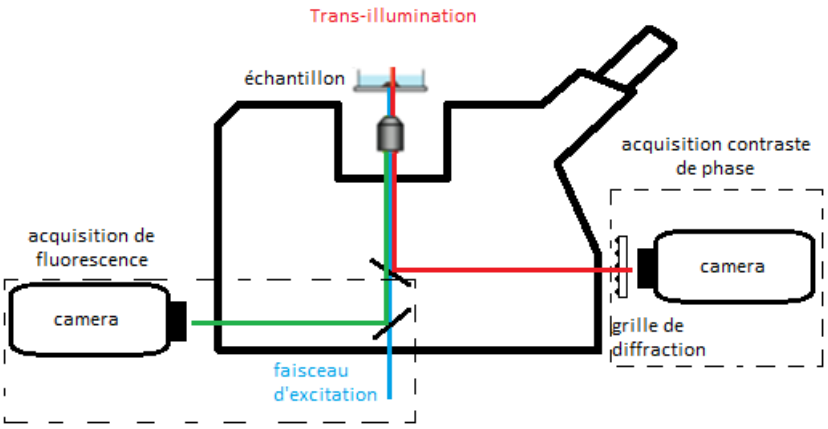


Figure 12 : Schéma simplifié du microscope d'acquisition de la mission de prédiction de fluorescence

2. *Mission de classification*

Pour la seconde mission dont l'objectif est la classification d'images de nanoparticules, seules des méthodes de machine learning non supervisé ont étaient testées. Les méthodes mises en place actuellement sont des méthodes de clustering avec k-means et des méthodes de réduction de dimensions comme l'analyse en composantes principales. Mon objectif pour cette mission est de réaliser un réseau de neurones pour classifier les individus et retrouver leur nature (Or, Argent, Plastique, Virus, …). L'acquisition n'est pas à ma charge, les pré-traitements correspondent à une propagation numérique et un calcul de certaines variables comme la taille de la nanoparticule, ils sont toujours effectifs. Les données sont des images d'intensité et de phase couplées aux variables calculées lors du pré-traitement. Le format des images est le même que le format des images de la mission de prédiction de fluorescence. Pour l'acquisition, les nanoparticules sont en solution aqueuse et diffusent librement par mouvement brownien (mouvement désordonné et aléatoire). L'acquisition de ces nanoparticules est une acquisition à haute cadence (400Hz), le pré-traitement permet de retrouver la position de la nanoparticule en profondeur dans le volume à chaque instant, s'ensuit alors un calcul d'une image moyenne sur plusieurs tranches de la vidéo. Les nanoparticules sont soumises à un mouvement brownien, ce mouvement induit une onde autour de la nanoparticule, en moyennant les différentes tranches de la vidéo après propagation numérique, on obtient une image de la nanoparticule : cette image est caractéristique de sa nature (comme pour la mission de prédiction de fluorescence, les images d'intensité et de phase sont reconstituées numériquement). On observe en **Figure 13** un exemple d'image de phase et d'intensité pour une nanoparticule.

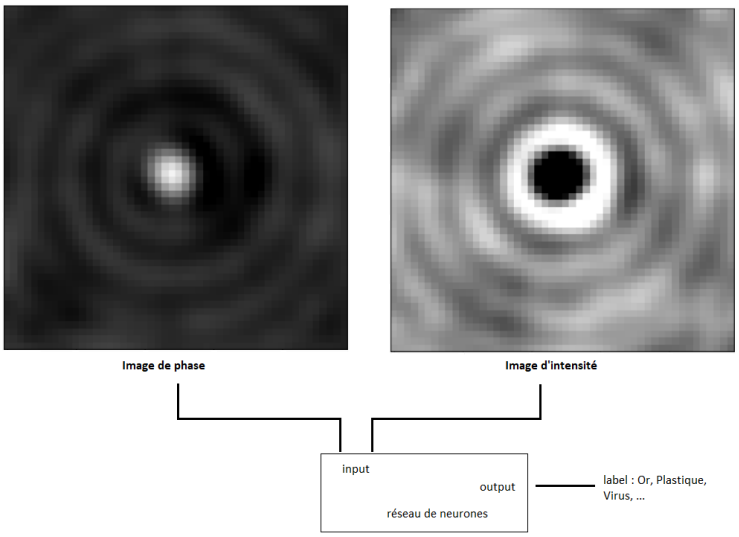


Figure 13 : Schéma illustrant l'objectif de la mission 2

2. Gestion de projet

a. Gestion du temps et organisation projet

Au début du stage, avec l'absence de contrainte de temps, le découpage temporel du stage était aisé. Les différents sous-objectifs et résultats n'impactaient pas cette répartition. Ainsi il était estimé que le stage serait découpé entre les deux missions avec une priorité sur la mission de prédiction de fluorescence, Un temps pour la rédaction du rapport et un temps pour la prise en main des existants était prévu. Le découpage initial suivait le découpage observé sur **l'annexe 3 : Gestion du temps, Gantt prévu**. Comme il s'agit d'un stage recherche exploratoire, nous n'avions qu'une vision fragmentaire sur le déroulement réel des missions impactées par les résultats et les réflexions, le Gantt initial était épuré. Cependant nous savions que l'activité de recherche et l'organisation projet imposeraient une certaine souplesse dans le planning, ce Gantt ne serait donc pas le Gantt final.

Le Gantt final observable en **annexe 4 : Gestion du temps, Gantt réel** est différent du Gantt initial. Les résultats, les réflexions et les contraintes temporelles ont impacté le déroulement des missions. Sur le Gantt final nous observons une forte disparité dans la répartition temporelle des missions, la mission principale n'est pas la mission qui occupe le plus de temps dans le planning. Un résultat prometteur et un besoin motivé par une date de publication proche ont donnés à la seconde mission un aspect prioritaire pour la fin du stage. Nous constatons aussi que les temps pour prendre en main les problématiques et compléter la mission 2 ont été sous-éstimés. Aussi nous voyons apparaître des précisions sur les différentes tâches effectuées.

Les missions s'inscrivent dans un cadre de recherche qui doit être souple. L'omniprésence d'essais-erreurs, de questionnements, d'analyses et de discussions sur les résultats impose une certaine souplesse pour nos missions. Pour favoriser cette souplesse quelques outils de suivi de résultats et de versions ont étaient mis en place. Dans un premier temps des discussions quotidiennes pour le suivi de la prise en main de l'existant : discussions devenues hebdomadaires avec la prise d'autonomie et de compétences sur les sujets. Pour le suivi de versions du code, un gitlab a était mis en place. Sur la **Figure 14** Nous observons le suivi de versions git pour la mission de prédiction de fluorescence.

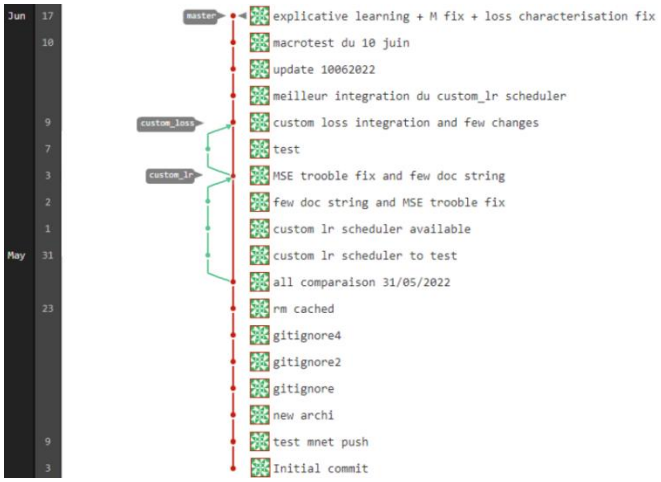


Figure 14 : Suivi de version git pour la mission de prédiction de fluorescence

b. Anticipation des risques

Pour ces deux missions un certain nombre de risques peuvent être anticipé. Le premier risque majeur concerne la mission de prédiction de fluorescence. L'objectif de cette mission est de prédire des images issues de la microscopie de fluorescence à partir d'images de fluorescence. Pour cette mission il faut éviter l'interpolation : nous souhaitons que la prédiction de fluorescence retourne l'image réelle que la microscopie de fluorescence nous permettrait d'obtenir. Actuellement la microscopie de phase permet d'imager un échantillon en mettant en évidence l'ensemble de la matière traversé. La prédiction de fluorescence n'a donc aucune raison de dériver vers une interpolation. Néanmoins il faut rester critique face à la résolution de nos microscopies : au sein d'une cellule d'une centaine de micromètres de longueur, réside certains éléments de tailles variables comme des mitochondries dont le diamètre usuel avoisine le micromètre ou encore des membranes de réticulum endoplasmique dont l'épaisseur avoisine les vingt nanomètres. Actuellement notre microscope de phase a une résolution de l'ordre de deux cents nanomètres. Avec une telle résolution une étude sur des mitochondries semble réalisable tandis qu'une étude sur les membranes des réticulums endoplasmique semble peu aisée.

Un second risque à anticiper concerne le nombre de données disponibles pour l'apprentissage de nos modèles. Les coûts de préparation cellulaire, les temps d'acquisition ainsi que les phénomènes de photoblanchiment et de phototoxicité sont des restrictions à l'acquisition pour la mission de prédiction de fluorescence. Concernant la mission de classification de particules, le temps de calcul et de pré-traitement ainsi que l'accès à certaines nanoparticules comme des nanoparticules virales disponibles uniquement en laboratoire de haut niveau de confinement sont des freins à l'acquisition. Le type de modèle mis en place dans la mission de prédiction de fluorescence peut se suffire d'un jeu de donnée peu étoffé cependant pour la mission de classification, les modèles les plus populaires sont des modèles à convolutions sans récurrence : ces modèles nécessitent des jeux plus volumineux. Pour la mission de prédiction de fluorescence, deux jeux de données sont disponibles : un jeu de données de mitochondries contenant 312 individus labélisés et un jeu de réticulum endoplasmique contenant 241 individus. Le jeu de réticulum est celui obtenus après suppression des individus dont la qualité de référence est insuffisante (349 individus avant sélection). Pour la mission de classification trois jeux sont à disposition : le premier jeu est un jeu constitué de 2630 individus labélisé pour 13 classes différentes, les deux suivants sont des jeux mixtes non labélisés de deux classes, contenant respectivement 197 et 196 individus.

Le troisième risque à considérer concerne la qualité des données. Pour la mission de prédiction de fluorescence, les acquisitions de fluorescence (pour la *ground thruth*) sont soumises aux contraintes liées à l'acquisition (photoblanchiment, phototoxicité, …) mais aussi aux problématiques d'intégration et d'expression de la fluorescence. Sur la **Figure 15** l'image **e** est représentative de la problématique d'intégration de la fluorescence tandis que les images **c** et **d** illustrent le contraste d'expression de fluorescence présent entre différentes cellules. Pour un réseau de neurones ce contraste peut être valorisé s'il concerne deux cellules sur deux images différentes considérées comme deux individus différents et donc comme deux scénarios distincts. Cependant pour une différence d'expression de fluorescence entre deux cellules d'une même image, la différence est comprise par le réseau de neurones comme un scénario unique et vient perturber l'apprentissage. Pour la mission de classification, les images sont obtenues par propagation numérique, si le nombre d'images utilisées pour la propagation est insuffisant alors la propagation fournira une image de qualité moindre. La présence de poussières ou les interférences entre les ondes browniennes de nos nanoparticules peut

aussi impacter la qualité des acquisitions. Sur la **Figure 15** les images **a** et **b** représentent des scénarios d'acquisition dont la qualité est moindre. **a** : on perd la partie haute de l'image, **b** : le signal central est dégradé).

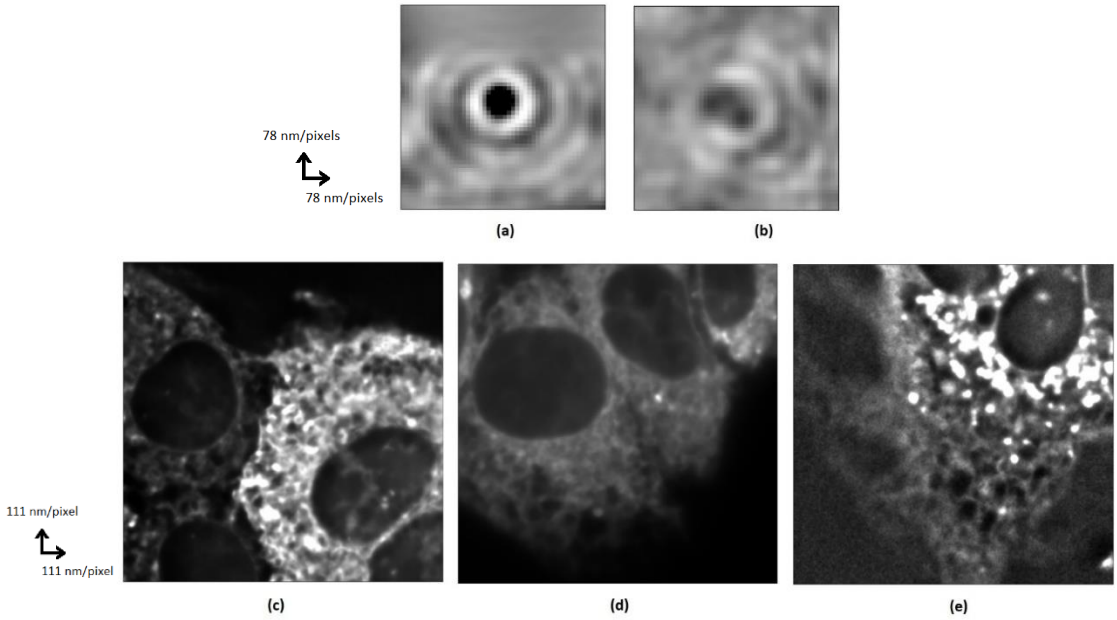


Figure 15 : Panel de données défavorable à l'apprentissage

Le quatrième risque concerne l'ordre de grandeur de nos images de phase et d'intensité. Ces ordres de grandeur ne sont pas homogènes entre la phase et l'intensité (voir **Figure 16**). Nous savons qu'une grande disparité entre les ordres de grandeur de nos variables d'entrées peut induire un phénomène d'apprentissage ciblé. Avec ce type d'entrée, la donnée qui possède le plus grand ordre de grandeur devient prioritaire dans l'apprentissage du réseau de neurones : les données avec les ordres de grandeur les moins importants finissent par devenir négligeable pour le réseau de neurones.

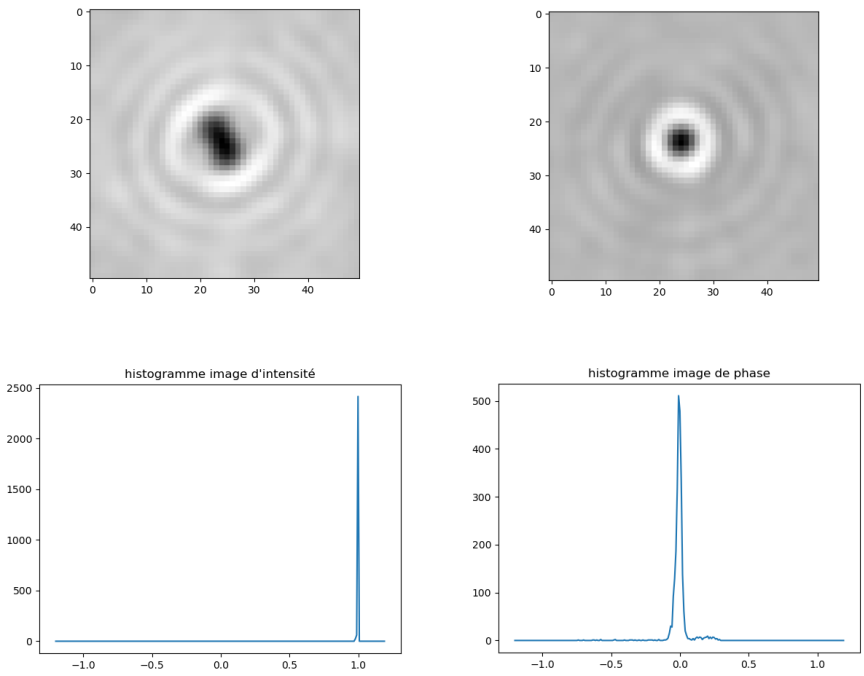


Figure 16 : Histogramme image de phase et image d'intensité

Le dernier risque concerne la paramétrisation des réseaux de neurones à déployer. Cette paramétrisation est fine et chaque paramètre est dépendant des autres. La **Figure 17** présente un ensemble réduit de paramètres pour un réseau de neurones.

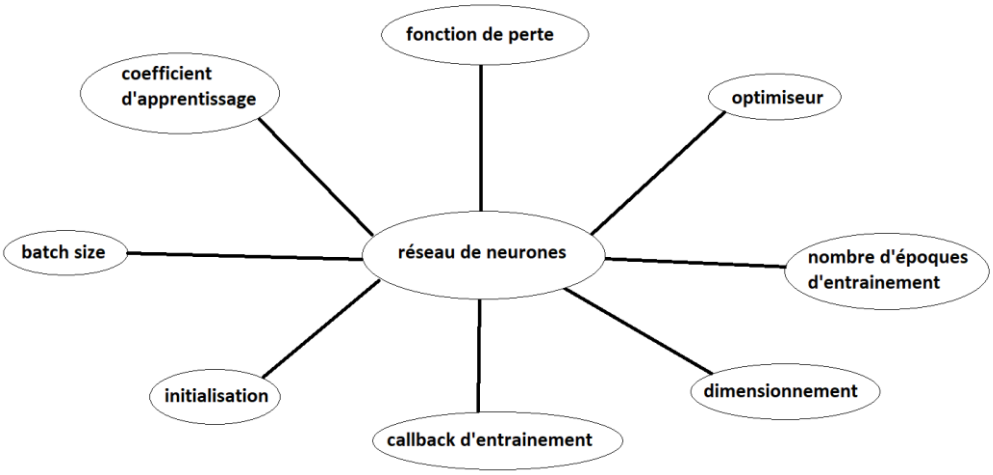


Figure 17 : Quelques exemples de paramétrisation pour un réseau de neurones

Les risques les plus importants concernent les données : le nombre et la qualité impactent grandement l'apprentissage de nos modèles. Si nous n'avons pas suffisamment de données alors nous ne parviendrons pas à déployer un modèle robuste faute de variabilité. Si la qualité de nos données est trop variable nous ne parviendrons pas à faire converger nos modèles.

3. Les existants

a. Existant de la mission de prédiction de fluorescence

i. Modèle et pré-traitement

Le modèle choisi pour réaliser les prédictions est le modèle U Net : Ce modèle est défendu dans la publication [5]. Sa capacité à compresser l'information de manière non linéaire rend ce réseau de neurones adéquat pour des applications médicales/biologiques où la quantité de données n'est pas toujours assurée. En effet il est expliqué dans la publication que le modèle U Net est comparable à ses paires (réseau de neurones convolutionnels) en therme de précision pour des jeux de données moindres. La compression non linéaire est la conséquence d'une certaine récurrence dans l'architecture. En **Figure 18** Nous retrouvons le schéma de l'architecture U Net, nous constatons la récurrence entre les couches de l'encodeur (descente) et les couches du décodeur (remontée) : cette récurrence permet de conserver une partie de l'information qui aurait été perdu lors de la compression vers l'espace latent.

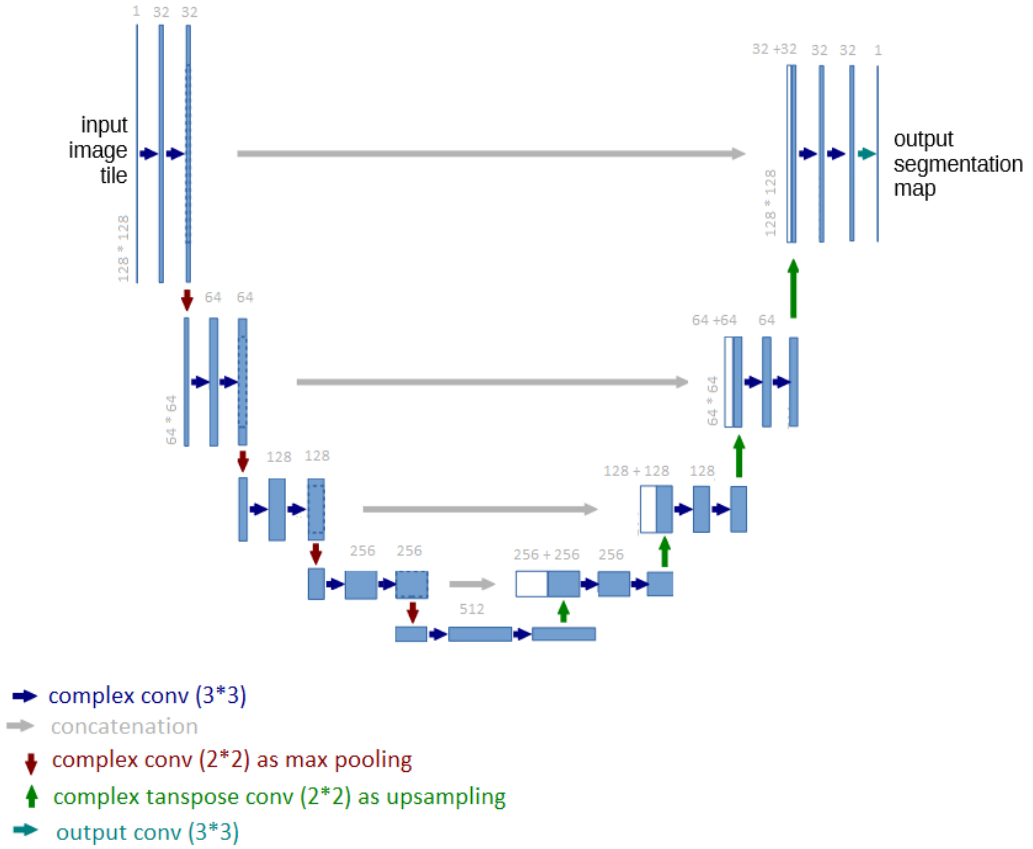


Figure 18 : Schéma de l'architecture U Net

Nous avons vu que deux pré-traitements étaient appliqués sur les acquisitions : le premier, toujours effectif correspond à un recalage entre les acquisitions fluorescentes et les acquisitions à contraste de phase. La précision sur la position incidente du faisceau optique sur une caméra est de l'ordre du micromètre : c'est-à-dire que l'on peut obtenir approximativement un micromètre de

décalage entre nos deux acquisitions. Les déviations des faisceaux sont aussi liées aux optiques utilisés, à l'objectif des caméras, à la distance parcourue par le faisceau, … C'est pourquoi les caméras ont été placées de telle sorte que le faisceau de fluorescence et le faisceau de lumière blanche parcours la même distance. C'est aussi la raison pour laquelle une étude des déformations induites par l'objectif des caméras est réalisée avant chaque acquisition. Le second pré-traitement est la déconvolution, ce traitement devient obligatoire lorsque l'on étudie des éléments de taille réduite et omniprésent au sein de l'échantillon. Les différentes acquisitions conduisent à des résultats 2D cependant ce sont des cubes complets qui sont acquis. La totalité de l'échantillon émet de la fluorescence par conséquent l'acquisition 2D contient les informations du cube 3D. Pour l'acquisition de contraste de phase, notre faisceau interagit avec l'ensemble de la matière constituante de notre échantillon, l'acquisition 2D contient les informations du cube 3D. La conséquence de représenter les informations d'un cube sur un plan est l'apparition d'informations résiduelles par l'augmentation de la quantité de basses fréquences dans l'image : l'acquisition 2D est réalisée autour d'une tranche du cube, les autres tranches sont alors projetées sur le plan choisi, créant ces nouvelles basses fréquences. Le formalisme mathématique de la déconvolution consiste à identifier la matrice inverse de l'impulsion à l'origine de la convolution. En **Figure 19**, nous observons un exemple d'application de recalage et un exemple de déconvolution.

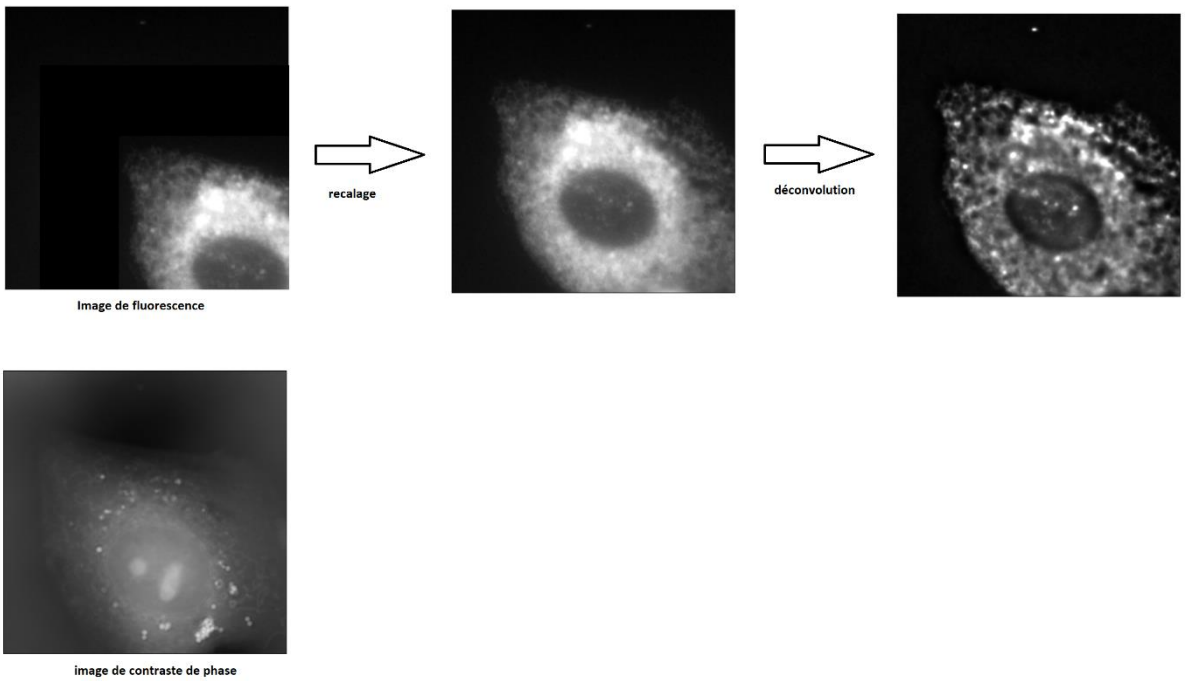


Figure 19 : Exemple d'un recalage et d'une déconvolution

Dans la partie anticipation des risques nous avons vu qu'il existe une différence d'ordre de grandeur entre l'intensité et la phase de l'acquisition de microscope à contraste de phase. La théorie nous explique que cette différence est directement liée à l'illumination utilisée. En théorie l'acquisition à contraste de phase est réalisée avec une illumination blanche, cependant en pratique nous devons réduire la plage de cette acquisition à l'aide d'un filtre pour éviter une excitation fluorescente résiduelle : dans notre cas les fluorophores utilisés sont excités pour des plages de longueurs d'onde proches de 600 nanomètres, l'illumination blanche est donc réduite autour de 525 nanomètres +/- 25

nanomètres. La théorie nous explique alors qu'il faut appliquer un coefficient équivalant à $\frac{\lambda}{4\pi}$ avec λ la longueur d'onde centrale de notre plage. Une étude a été faite pour l'existant afin de déterminer numériquement ce coefficient. En **Figure 20** nous retrouvons le résultat de cette étude où plusieurs coefficients ont été mis en compétition et évalués avec la précision obtenue en fin d'entrainement. Il s'avère que la théorie s'applique à notre étude.

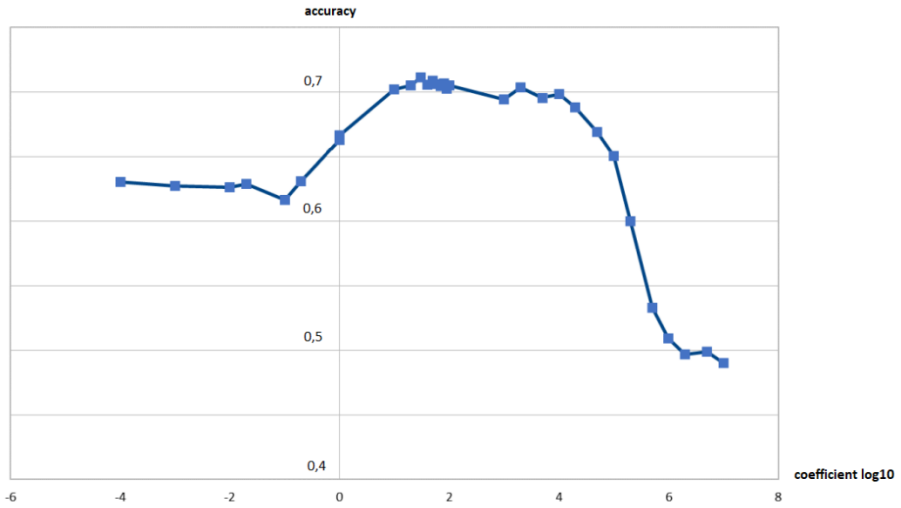


Figure 20 : Recherche numérique du coefficient d'égalisation d'ordre de grandeur intensité/phase optimal

ii. Modèle et couches complexes

L'existant est donc un modèle U Net utilisant des données recalées, parfois déconvoluées en considérant l'égalisation entre phase et intensité. Si l'existant actuel utilise le couple phase intensité c'est parce que les études préliminaires ont montré que la phase seule ne permet pas une prédiction de fluorescence aussi fine : il a été montré que coupler la phase et l'intensité permettait un gain de 20% sur la précision de prédiction de fluorescence finale. L'acquisition de contraste de phase est une acquisition dont les valeurs sont dans le domaine complexe avec l'intensité comme constituant majeur de la partie réel et la phase comme constituant majeur de la partie imaginaire. Travailler avec la phase uniquement revient à se séparer de la moitié des informations disponibles.

Pour réaliser des prédictions de fluorescences sur des images complexes, des réseaux de neurones complexes sont nécessaires. La publication [4] nous présente le formalisme mathématique des couches complexes que nous utiliserons. La première couche complexe è considérer est la couche de convolution complexe. Nous rappelons que les couches de convolutions usuelles opèrent une convolution entre une image et un noyau de taille réduite. Le résultat de cette opération et d'une chaîne de convolutions permet de compresser les données initiales et d'extraire des descripteurs pour ces images. Dans le cas complexe nous devons traiter deux images, une image de phase et une image d'intensité. La convolution complexe est étendue avec l'utilisation de noyaux distincts pour la partie réelle et la partie imaginaire : une convolution croisée est alors effectuée. D'ordinaire l'opération de convolution est caractérisée par l'équation $h_{i+1} = W * h$ avec W le noyau, h l'image à convoluée et h_{i+1}le résultat de la convolution (la convolution complexe peut aussi s'appliquer sur un vecteur h de dimension 1,3, …). Pour une convolution complexe h et W deviennent complexes et de la forme $z =$

$a + ib$, nous pouvons donc écrire $h = x + iy$ avec x l'image d'intensité et y l'image de phase ainsi que $W = A + iB$ avec A le noyau réel et B le noyau imaginaire. Un schéma illustrant la convolution complexe est visible en **Figure 21**. La nouvelle convolution est $W * h = (A * x - B * y) + i(A * x + B * y)$.

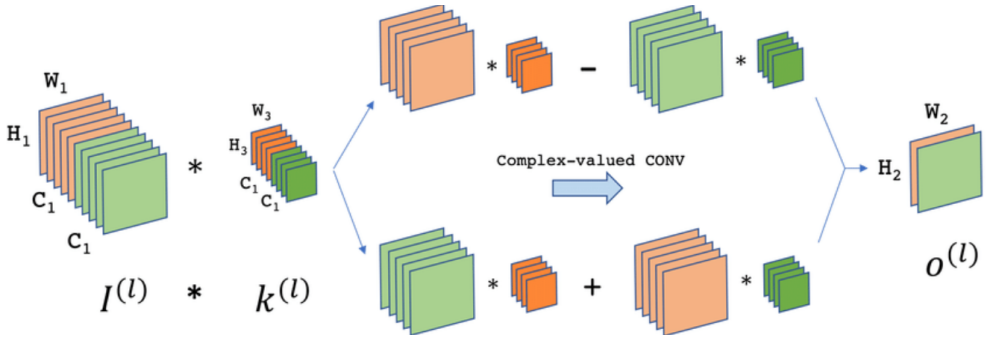


Figure 21 : Couche de convolution complexe

Les couches linéaires complexes fonctionnent selon le même principe que les couches convolutionnelles complexes. La différence réside dans la définition de W et de h, pour les couches linéaires W correspond aux poids de la couche et h est un vecteur à une dimension.

Pour les fonctions d'activations, nous utiliserons majoritairement ReLu et Softmax. ReLu possède trois définitions distinctes. Nous pouvons appliquer ReLu sur le module de notre entrée, cette solution est appelée modReLu et présente un désavantage qui est de ne pas être holomorphe (dérivable infiniment et égal à la somme de sa série de Taylor en tout point). Nous pouvons appliquer ReLu sur la partie réelle et la partie imaginaire séparément, ces deux parties pourront alors être nul indépendamment, cette méthode s'appelle CReLu. Nous pouvons appliquer ReLu avec un ET logique, la partie réelle et la partie imaginaire doivent alors toutes deux être positives, cette méthode s'appelle ZReLu. La **Figure 22** nous présente ces trois scénarios. Pour Softmax, plusieurs scénarios crédibles sont possibles, une moyenne entre Softmax réel et imaginaire, une multiplication entre les deux Softmax, Softmax appliquer sur la multiplication précédente, … L'objectif est de maintenir la sortie entre 0 et 1 en valorisant autant l'information issue de la partie réelle que l'information issue de la partie imaginaire.

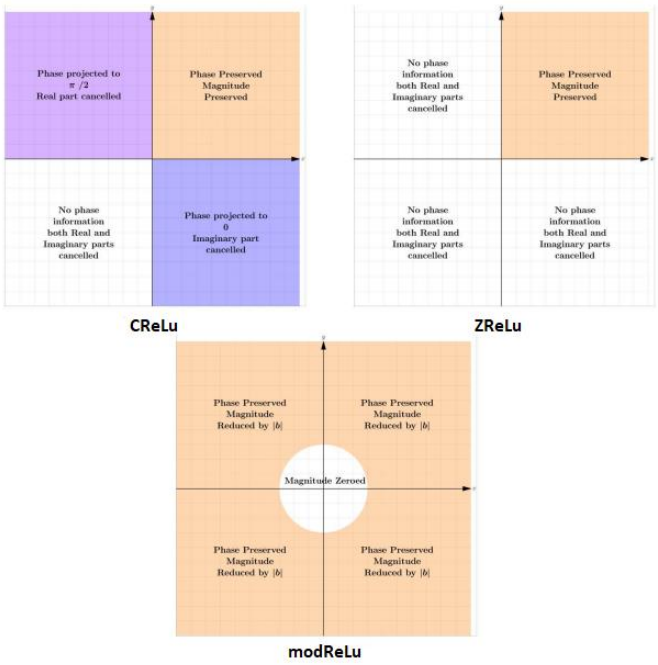


Figure 22 : Présentation des scénario ReLu complexe

La normalisation par lots classique tend à rendre la moyenne de nos entrées nulles et la variance égale à 1. La normalisation par lots complexe ne peut fonctionner de la même sorte : il faut faire attention à maintenir une variance similaire entre la partie réelle et la partie imaginaire c'est-à-dire qu'il faut parvenir à décorréler partie réelle et partie imaginaire. Pour réaliser cette opération nous devons multiplier nos données centrées par l'inverse de la matrice de covariance :

$\tilde{x} = (V)^{\frac{1}{2}}(x - E[x])$. Avec x notre vecteur d'entré, $E[x]$ le vecteur moyenne et V la matrice de covariance.

L'expression de la matrice de covariance est alors :

$$V = \begin{bmatrix} V_{rr} & V_{ri} \\ V_{ir} & V_{ii} \end{bmatrix} = \begin{bmatrix} cov(Re\{x\}, Re\{x\}) & cov(Re\{x\}, Img\{x\}) \\ cov(Img\{x\}, Re\{x\}) & cov(Img\{x\}, Img\{x\}) \end{bmatrix}.$$

b. Existant de la mission de classification

Nous avons vu que l'existant de la mission de classification utilise des images de nanoparticules issues de la microscopie à contraste de phase. Ces nanoparticules étant immergé dans un volume, une première contrainte est d'isoler leur position réelle. Une fois leur position réelle retrouvée, il faut reconstruire l'image la plus fidèle possible, comprenant la nanoparticule et ses ondes browniennes. Les ondes browniennes correspondent aux cercles centrés autour de la nanoparticule, visible sur la **Figure 16** ou la **Figure 15**. Chaque nanoparticule possède un mouvement brownien, lié à sa nature. La reconstruction s'opère par propagation numérique et en utilisant des captures de la dynamique des nanoparticules.

Pour cet existant, seules des méthodes de classification non supervisée ont été mise en place. Ce sont des méthodes de réduction de dimensions comme l'analyse en composantes principales (ACP) et des méthodes de clustering comme k-means. Nous retrouvons un exemple de clustering en **Figure 23**, l'enjeu de ce clustering était lors de séparer des nanoparticules d'or et de polystyrène. Le clustering en **Figure 23** utilise des descripteurs non linéaires des images de nanoparticule comme variable. Ces variables sont la taille de la nanoparticule et deux nombres appelés « réel de Rytov » et « imaginaire de Rytov ». Les deux dernières variables sont extraites des images de notre nanoparticule traité par approximation de Rytov.

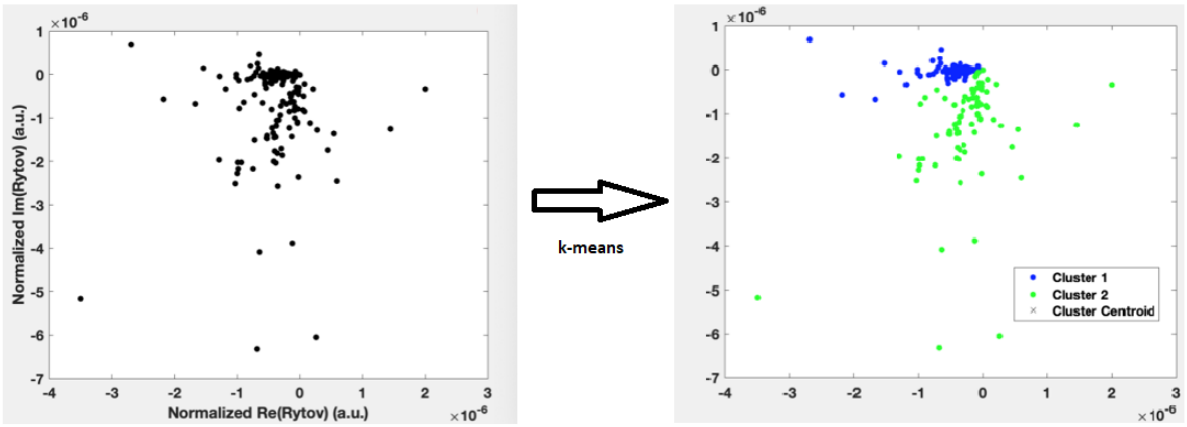


Figure 23 : Illustration de k-means appliqué sur les variables extraites des images de nanoparticule

L'objectif de la mission de classification est de réaliser une classification sur un ensemble de nanoparticules dont la nature est inconnue, k-means nécessite de connaître le nombre de clusters à former, aussi il présente certains désavantages comme sa sensibilité aux outliers. Dans notre étude k-means ne semble pas être l'algorithme optimal. Concernant l'analyse en composante principale : cette analyse est valable uniquement pour des variables numériques, notre objectif est de nous séparer de toute variable numérique pour réaliser une classification sur des images. L'idée est d'opéré une classification fine en un temps réduit c'est pourquoi nous préfèrerons se concentrer sur les images.

Aussi les caractéristiques des jeux labélisés disponibles tendent à éliminer la possibilité d'une classification précise avec des méthodes non supervisées. En **Figure 24** nous retrouvons la dispersion de notre jeu labélisé et en **Figure 25** nous retrouvons les diagrammes boîtes de nos différentes classes. La superposition des différentes classes est une contrainte qui invalide l'usage de méthode comme k-means nécessitant des clusters dont la forme est circulaire et avec des variances inter-clusters importante ou encore l'usage d'une analyse en composante principale nécessitant des variables avec des corrélations variables. Dans notre cas les clusters sont difformes, avec la présence d'outliers et avec des variances inter-clusters faible favorisant la superposition des classes.

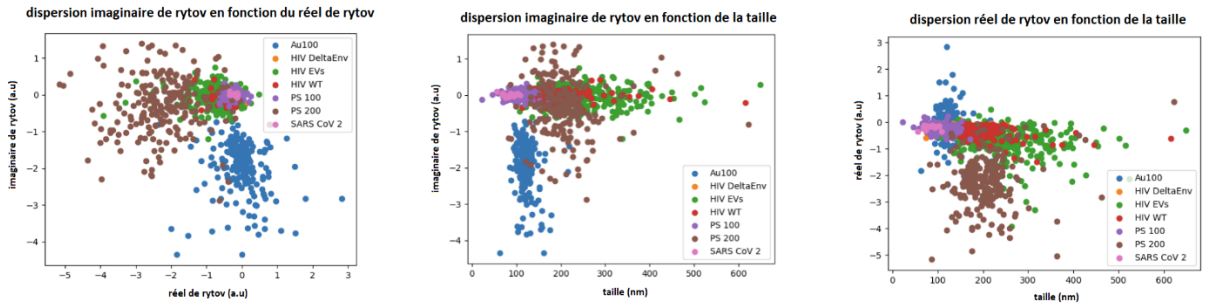


Figure 24 : Dispersion du jeu de donnée labélisé

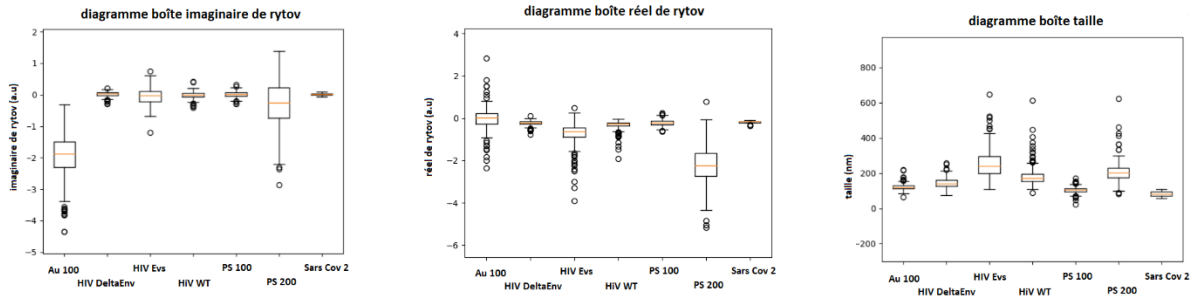


Figure 25 : Diagramme boîte du jeu labélisé

L'ambition de la mission de classification est d'utiliser un réseau de neurones. Nous avons vu qu'il y avait un risque sur le nombre de données disponibles. Pour la mission de prédiction de fluorescence ce risque est contourné grâce à l'architecture U Net. Pour cette mission, la forte symétrie de nos images va permettre d'outrepasser le besoin de jeu de données macroscopiques. Le nombre de scénarios possible est réduit grâce aux symétries, par conséquent notre réseau de neurones a peu de variabilités à apprendre.

4. Résultats et discussions de la mission de prédiction de fluorescence

a. U Net

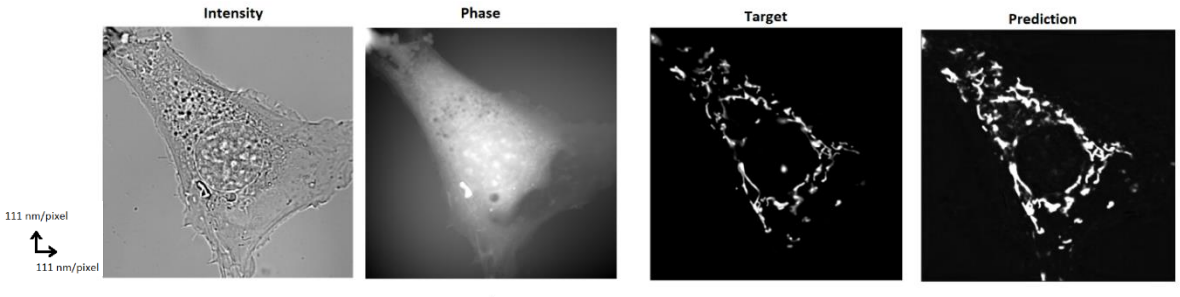
Nous avons vu que le réseau de neurones choisi pour compléter la mission de prédiction de fluorescence était un réseau U Net, ce réseau a pour avantage d'être moins sensible au jeu de faible taille et permet de conserver plus d'informations lors de la compression que les réseaux de neurones convolutionnels usuels. Un schéma de l'architecture est disponible en **Figure 18**. La paramétrisation est la suivante :

- Quatre étages de décodeur et d'encodeur
- Présence de couches de normalisation de lots
- Utilisation de couche convolutionnels comme fonction maxpooling et upsampling

- Un coefficient d'apprentissage de 0,001
- Un Batch size de 24
- Soixante époques d'entrainement
- Absence de variation du coefficient d'apprentissage lors de l'entrainement
- Un optimiseur Adam classique
- la fonction des moindres carrés comme fonction de perte

Ces paramètres ont été déduit antérieurement à cette étude, ils sont amenés à changer lors de la progression de la mission. Aussi nous rappelons que le jeu de données labélisées est découpé en patch lors de l'entrainement. La prédiction est réalisée sur des images entières.

Nous réalisons deux entrainements pour tester les capacités de l'architecture. Le premier entraînement est réalisé sur un jeu de données de mitochondries : la fluorescence, considérée comme label, met en évidence les mitochondries des cellules acquises et l'objectif de l'entrainement est d'apprendre à notre réseau à prédire des images de fluorescence. En d'autres termes, nous nous attendons à ce que le réseau de neurones une fois entraîné puisse reconstruire des images de fluorescence mettant en évidence les mitochondries. Le deuxième entraînement concerne le réticulum endoplasmique. Un exemple de prédiction de mitochondries ainsi qu'un échantillon des métriques d'évaluations du modèle sont disponibles en **Figure 26** et une superposition d'image de prédiction, d'intensité et de label est visible en **Figure 27**.



	global Pearson	MSE	dice	Jaccard
Mean	0,80	0,01	0,07	0,55
Sum	250,40	2,20	20,51	172,65

mean accuracy : 0.94
mean precision : 0.67
mean recall : 0.75

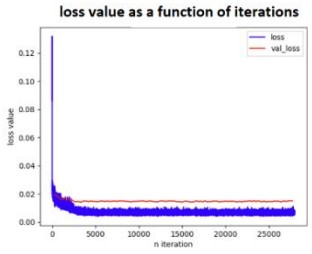


Figure 26 : Résultats de prédiction de fluorescence de mitochondries avec U Net

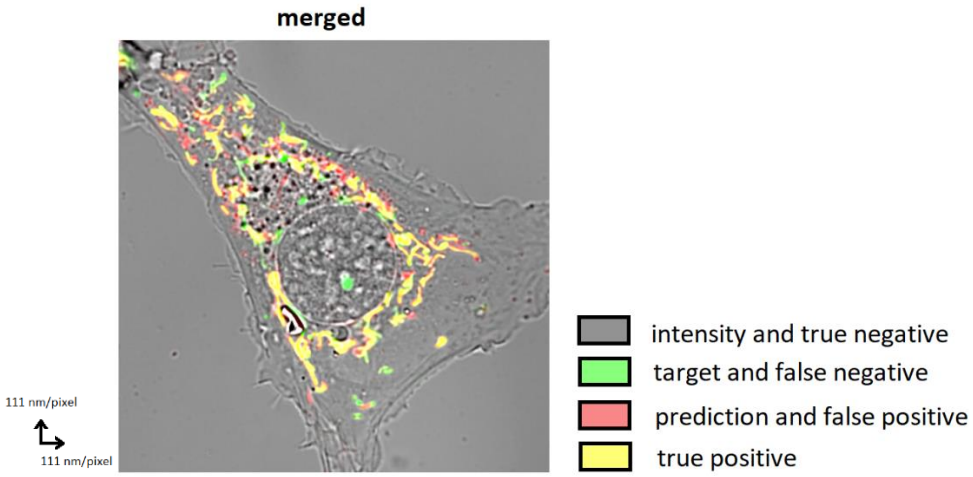


Figure 27 : superposition de prédiction, de label et d'image d'intensité pour les mitochondries avec le modèle U Net

Plusieurs résultats concernant la prédiction de fluorescence de mitochondries sont encourageants. L'image de prédiction en **Figure 26** est similaire au label (« *target* »). Ce résultat est confirmé avec la superposition observable en **Figure 27**. Cette similarité est répliquée sur l'ensemble de notre jeu de données, les métriques de précision moyenne, justesse moyenne et rappel sont le témoignage de cette réplicabilité. La précision qui correspond à la proportion de vrai positif (en jaune dans la superposition), elle est de 94% sur l'ensemble du jeu. La justesse correspond à la proportion de vrai positif parmi les vrais positifs et les faux positifs, elle est de 67%. Le rappel correspond à la proportion de vrais positifs parmi les vrais positifs et faux négatifs, il est de 75%. En moyenne, notre modèle est suffisamment précis pour être utilisé pour ce type de problématique, il produit néanmoins une part non négligeable de faux positifs (en rouge dans la superposition) et une part moins importante de faux négatif (en vert dans l'image). Dans notre cas, nous souhaitons une proportion de faux négatifs et de faux positifs négligeable, la proportion actuelle de ces deux ensembles est jugée négligeable par les experts biologistes. L'évolution de la fonction de perte en fonction des itérations confirme l'absence de sur-apprentissage ou sous-apprentissage. Des métriques supplémentaires appuient la qualité des prédictions : la corrélation moyenne entre les labels et les prédictions est de 0,80, c'est une forte corrélation.

Concernant la prédiction de fluorescence de réticulum endoplasmique, les résultats laissent place à une amélioration. Les métriques de précision, de justesse et de rappel sont de l'ordre de 50%. Même si les experts biologistes sont enthousiastes vis-à-vis de nos prédictions de fluorescences, les images prédites de réticulum endoplasmique sont jugées plus rudement que les images prédites de réticulum. L'optimisation de la qualité de nos prédictions de réticulum endoplasmique est un besoin réel.

Dans cette partie nous avons tenté de réaliser une prédiction de fluorescence avec un modèle U Net. Les résultats sont mitigés avec une bonne prédiction pour les mitochondries et une prédiction améliorable pour le réticulum endoplasmique. Pour parvenir à réaliser une meilleure prédiction de fluorescence sur nos images de réticulum endoplasmique, nous devons nous concentrer sur les points fondamentaux de notre problème : nous cherchons à extraire l'information d'une image pour en

produire une autre. La fonction de perte des moindres carrés n'est pas adaptée pour un travail sur des images. Nous allons donc focaliser notre attention sur cette fonction de perte.

b. Utilisation de la corrélation de Pearson comme fonction de perte

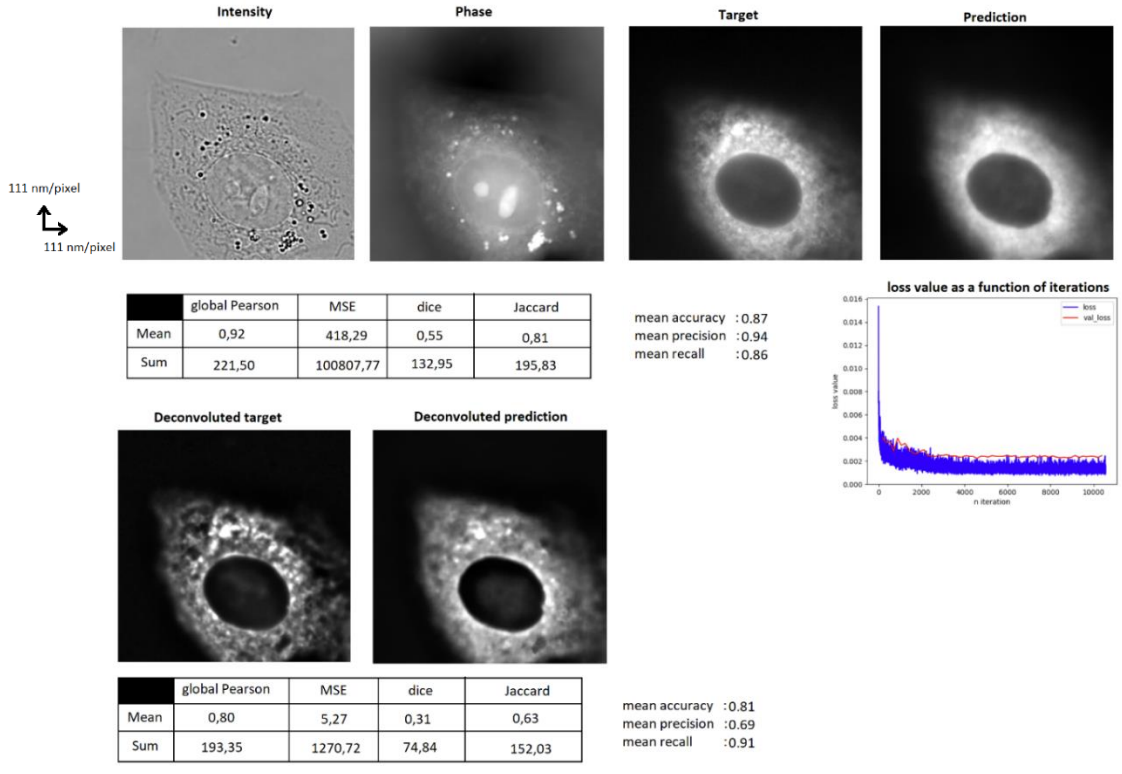
Nous savons que la fonction de perte des moindres carrés ne convient pas à l'ensemble de nos scénarios de prédiction de fluorescence. Nous choisissons de la remplacer par une nouvelle fonction de perte basée sur la corrélation de Pearson. Désormais le modèle réalise une corrélation entre les images labels et les images prédites, la définition de notre nouvelle fonction de perte est : $\frac{|corrélation-1|}{2}$. La corrélation est appliquée suivant le principe des couches convolutionnels : un noyau (3*3 ou 5*5 ou …) se déplace sur nos images, à chaque position la corrélation est calculée :

$$correlation = \frac{\sum(x-m_x)(y-m_y)}{\sqrt{\sum(x-m_x)^2}\sqrt{\sum(y-m_y)^2}}$$

avec x et m_x les valeurs de l'image prédite comprises dans le noyau et la moyenne de ces valeurs, y et m_y concernent l'image *ground truth*.

Nous avons choisi la corrélation de Pearson en adéquation avec notre besoin de créer une prédiction de fluorescence identique aux labels : cette nouvelle métrique de pertes est insensible aux variations d'intensité du signal fluorescent entre deux images).

Nous retrouvons en **Figure 28**, les résultats après utilisation de la fonction de perte Pearson pour le jeu de données de réticulum endoplasmique. En **Figure 29** on retrouve la superposition pour compléter la visualisation des résultats.



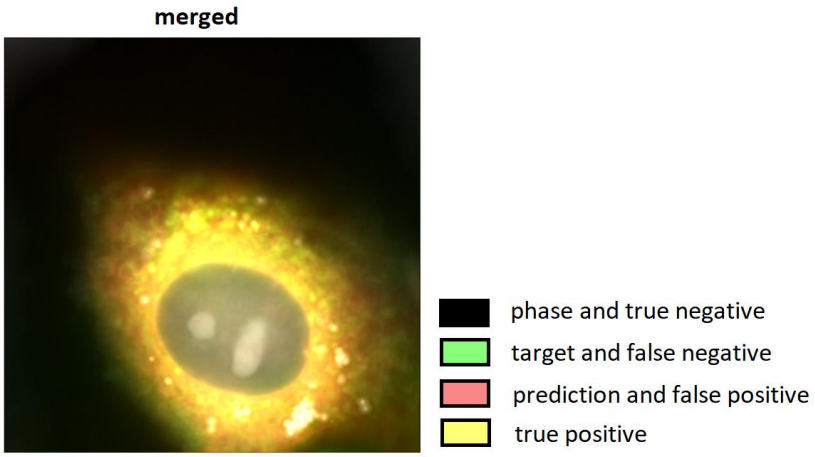
	global Pearson	MSE	dice	Jaccard
Mean	0,92	418,29	0,55	0,81
Sum	221,50	100807,77	132,95	195,83

mean accuracy :0.87
mean precision :0.94
mean recall :0.86

	global Pearson	MSE	dice	Jaccard
Mean	0,80	5,27	0,31	0,63
Sum	193,35	1270,72	74,84	152,03

mean accuracy :0.81
mean precision :0.69
mean recall :0.91

Figure 28 : Résultats de prédiction de fluorescence avec la corrélation de Pearson comme fonction de perte



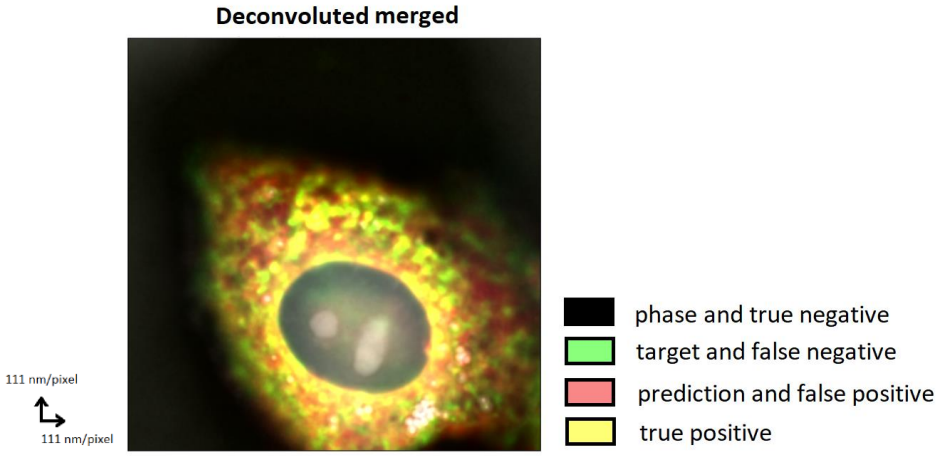


Figure 29 : superposition de label, prédiction et image de phase pour le réticulum endoplasmique avec U Net et Pearson

Nous rappelons que nous disposons de deux jeux pour le réticulum endoplasmique : un jeu traité par une déconvolution visant à effacer l'impact de la fluorescence issue des tranches non étudiées et un jeu non traité par déconvolution. Les résultats concernant ces deux jeux, sont de meilleures qualités que les résultats issus de l'entrainement avec les moindres carrés comme fonction de perte. Les images prédites sont exploitables. Les métriques de précision, justesse et rappel confirment la qualité de nos prédictions. Pour le jeu non traité, la proportion de faux négatifs est plus importante que la proportion de faux positifs et la précision est importante. Néanmoins nous devons rester critique : notre prédiction est constituée majoritairement de basses fréquences sur un fond noir, notre acquisition soumise aux contraintes de résolution produit elle aussi majoritairement des basses fréquences sur fond noir. La précision observée est compliquée à évaluer : nous pouvons uniquement statuer sur le fait que notre prédiction parvient bien à reproduire des basses fréquences. En observant la superposition, nous constatons une part importante de pixel rouge et vert en périphérie de la cellule : ces pixels correspondent à des faux positifs et des faux négatifs. Au bord de la cellule les phénomènes de convolutions sont moins importants, par conséquent il y a une proportion de hautes fréquences plus importante. Les erreurs en périphérie de la cellule sont le témoignage de l'incapacité de notre modèle à reproduire fidèlement les hautes fréquences d'une image de réticulum endoplasmique. Concernant le jeu de données déconvoluées, les prédictions semblent plus réalistes

toutefois la superposition met en lumière les faiblesses de ces dernières. Il est possible que ces manques soient dus à notre modèle. Les résultats concernant les mitochondries restent exceptionnels.

La prédiction de fluorescence du réticulum endoplasmique avec la nouvelle fonction de perte est meilleure, cependant il reste une marge de progression importante. Pour la suite de la mission, la corrélation de Pearson est la fonction de pertes que nous utiliserons. Nous rappelons que le réticulum endoplasmique est plus précisément sa membrane, à une épaisseur d'une vingtaine de nanomètres et que celui-ci est donc complexe à imager avec une microscopie dont la résolution est de l'ordre de 200 nanomètres. Néanmoins nous souhaitons améliorer les résultats de prédiction. Nous choisissons de travailler sur l'architecture U Net : l'objectif est de tester de nouveau réseau de neurones proche du U Net.

c. Variation du U Net

Deux architectures sont mises en concurrence avec l'architecture U Net. La première est appelée M Net, son schéma est disponible en **Figure 30**, la seconde est appelée Multires U Net avec son schéma en **Figure 31**.

Nous savons que le U Net permet une certaine conservation de l'information initiale, cependant cette conservation peut être optimisée : Le M Net cherche à optimiser cette conservation d'informations. Comparé au U Net, le M Net présente deux nouvelles branches, une branche gauche contenant de l'information initiale injectable dans le réseau à chaque étage de l'encodeur et la branche droite contenant de l'information issue de l'espace latent et accessible à chaque étage du décodeur. Le M Net est défendu dans la publication [6] pour des applications de prédiction de fluorescence en médecine.

La principale force du réseau U Net est sa redondance entre l'encodeur et le décodeur : cette redondance permet une compression non linéaire et est assurée par une simple opération de copie et de concaténation. L'objectif de l'architecture Multires U Net est de remplacer cette simple opération par une série de convolutions et de concaténation. Sur la **Figure 31**, le « *Res Path* » correspond à la nouvelle suite d'opérations. Un autre enjeu du Multires, présenté dans la publication [7], est d'accélérer le temps d'entrainement et de prédiction d'un réseau U Net classique. Les opérations classiques réalisées à chaque étage sont remplacées par les opérations visibles sur la figure.

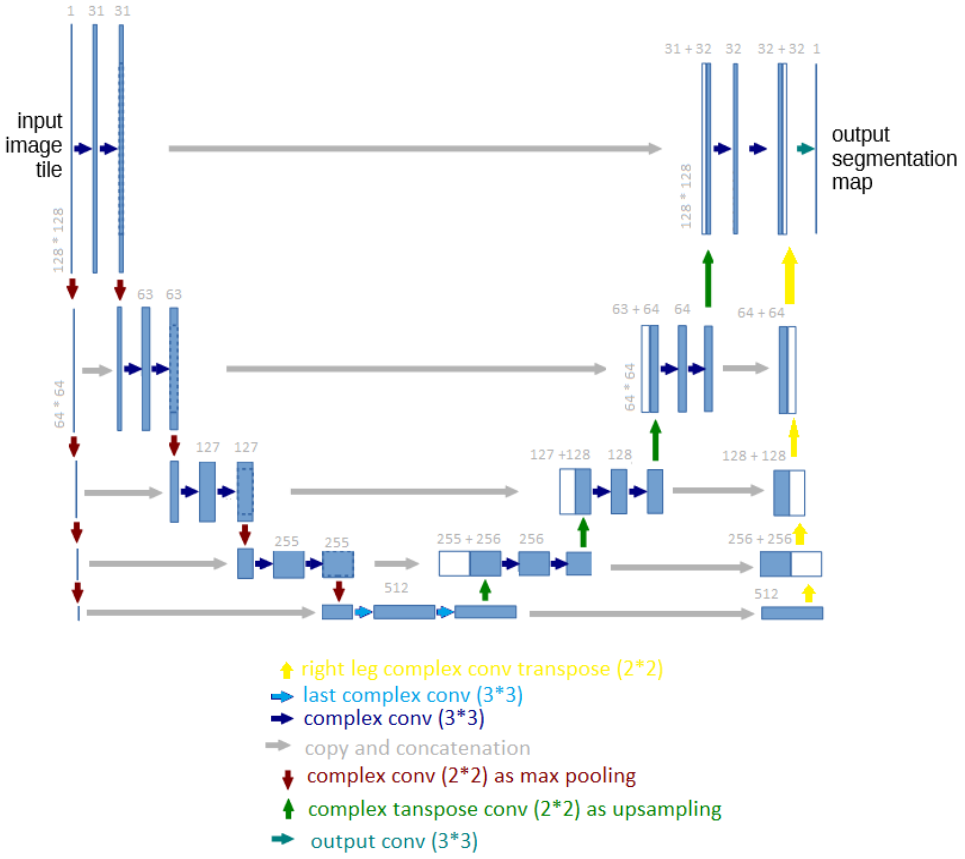


Figure 30 : schéma du M Net

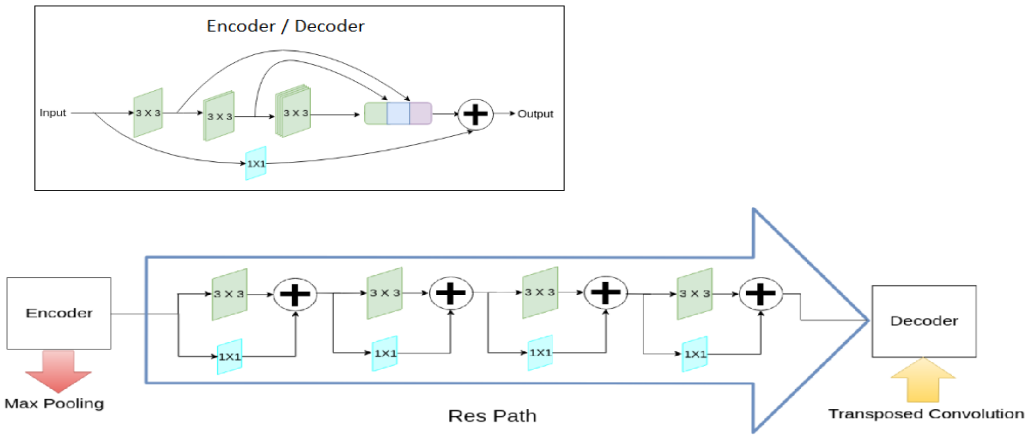
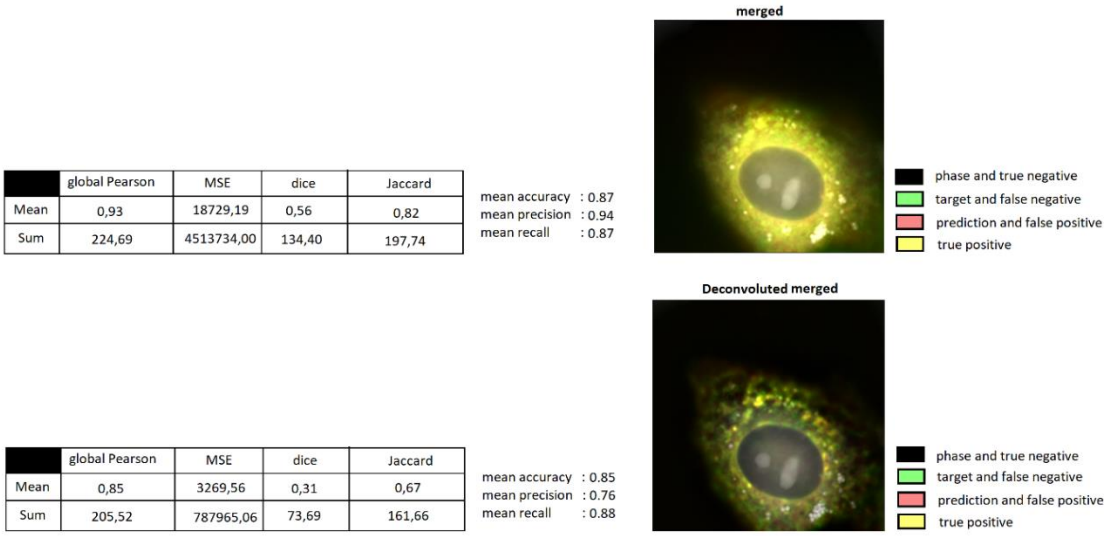


Figure 31 : Schéma du Multires U Net

Les premiers tests sur les mitochondries révèlent que les nouvelles architectures produisent des résultats similaires au U Net. L'amélioration attendue n'est pas constatable sur les images de mitochondries cependant les précédents résultats ne laisser que peu de marge pour une amélioration. Pour le temps de calcul, le Multires n'a pas accéléré l'entrainement comme présentée dans la publication associée, ce résultat est majoritairement dû à l'utilisation de nos couches de convolution comme *maxpooling* et *upsampling*.

En **Figure 32** et **33** nous observons respectivement les résultats d'entrainement du M net et du Multires Net sur le réticulum endoplasmique.



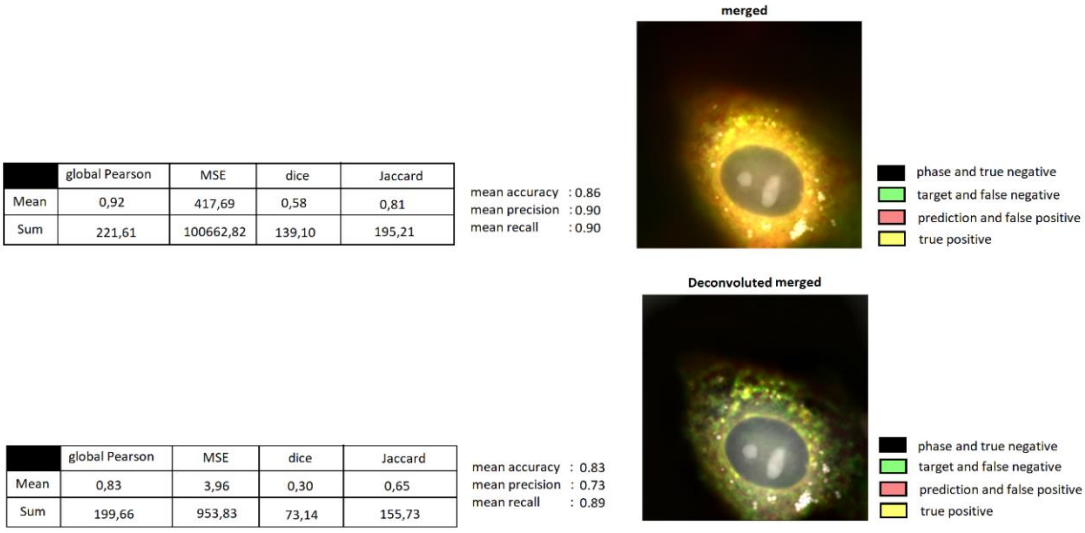
	global Pearson	MSE	dice	Jaccard
Mean	0,93	18729,19	0,56	0,82
Sum	224,69	4513734,00	134,40	197,74

mean accuracy : 0.87
mean precision : 0.94
mean recall : 0.87

	global Pearson	MSE	dice	Jaccard
Mean	0,85	3269,56	0,31	0,67
Sum	205,52	787965,06	73,69	161,66

mean accuracy : 0.85
mean precision : 0.76
mean recall : 0.88

Figure 32 : Résultats de prédiction de fluorescence de réticulum endoplasmique avec M Net



	global Pearson	MSE	dice	Jaccard
Mean	0,92	417,69	0,58	0,81
Sum	221,61	100662,82	139,10	195,21

mean accuracy : 0.86
mean precision : 0.90
mean recall : 0.90

	global Pearson	MSE	dice	Jaccard
Mean	0,83	3,96	0,30	0,65
Sum	199,66	953,83	73,14	155,73

mean accuracy : 0.83
mean precision : 0.73
mean recall : 0.89

Figure 33 : Résultats de prédiction de fluorescence de réticulum endoplasmique avec Multires U Net

Les résultats observés sont similaires aux résultats du U Net. Après une suite d'entrainements, il apparaît que les nouveaux modèles produisent des prédictions dont la qualité est identique aux prédictions du U Net. Cette similitude dans la prédiction induit que l'apport de redondance du M et le renforcement de la redondance du Multires ne sont actuellement pas valorisables. Aussi la reconstruction des hautes fréquences de nos images reste une de nos problématiques.

Dans cette partie nous avons tenté de remplacer l'architecture U Net par une architecture offrant une meilleure redondance d'information. Les architectures de remplacements produisent des résultats similaires à l'architecture U Net. Nous pouvons conclure que l'architecture U Net est suffisante pour notre étude. Nous allons donc nous concentrer sur la paramétrisation interne du U Net pour la suite de la mission. Nous allons travailler sur le coefficient d'apprentissage de telle sorte que notre modèle est une convergence plus rapide et plus précise.

d. Utilisation d'un ajusteur automatique de coefficient d'apprentissage

Nous réalisons un ajusteur automatique de coefficient d'apprentissage. Cet ajusteur reprend le fonctionnement usuel des ajusteurs classiques. Une mécanique de mémoire et de patience est donc mise en place pour contrôler la mise à jour du coefficient d'apprentissage. La particularité de notre ajusteur est qu'il utilise une fenêtre. Un schéma est disponible en **Figure 34**. Sur une fenêtre de temps nous enregistrons les pertes associées, une fois la fenêtre complétée, une fonction linéaire est interpolée sur l'ensemble des valeurs enregistrées, la pente de cette fonction devient la métrique utilisée pour mettre à jour notre coefficient d'apprentissage. Si cette métrique n'est pas inférieure à la métrique en mémoire, pendant n fenêtrage alors le coefficient est multiplié par 0,95.

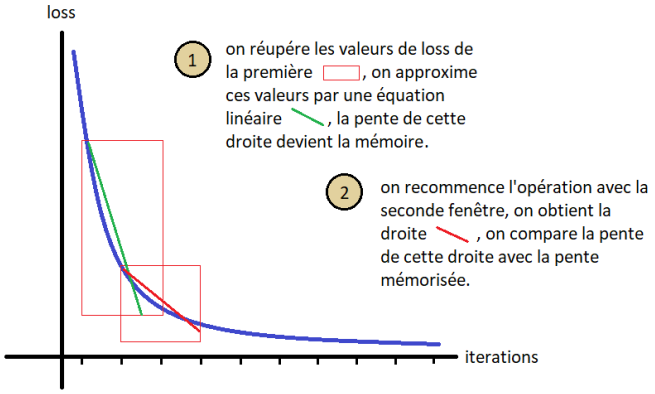


Figure 34 : Fonctionnement de l'ajusteur automatique de coefficient d'apprentissage

Les résultats obtenus avec notre ajusteur automatique ne sont pas concluants : nous parvenons bien à utiliser l'ajusteur cependant sa paramétrisation n'est pas aisée : la patience (nombre d'occurrence avant mise à jour), le coefficient multiplicatif pour la mise à jour, la taille de la fenêtre, l'écart entre les fenêtres et le paramètre pour estimer que la pente i+1 est bien inférieure à la pente i sont autant de paramètre à ajuster.

Jusque-là, notre étude a révélé l'importance du choix de la fonction de perte et la difficulté de nos modèles à reproduire les hautes fréquences de nos images de réticulum endoplasmique. Aussi nous avons choisi de conserver le modèle U Net comme modèle unique. L'ajusteur automatique de coefficient d'apprentissage ne nous a pas permis de régler le problème des hautes fréquences.

e. Corrélations de Pearson hautes et basses fréquences comme fonction de perte

Pour forcer notre modèle à apprendre à reconstruire les hautes fréquences des images de réticulum endoplasmique, nous mettons en place une nouvelle fonction de perte. Cette nouvelle fonction correspond à une corrélation de Pearson appliquée sur les basses et les hautes fréquences de nos images. L'application d'un poids sur les hautes et les basses fréquences permet de contrôler l'importance de chacune dans l'apprentissage. La nouvelle fonction de perte est : $\frac{a\times|corrélation\ basse\ fréquence-1|+b\times|corrélation\ haute\ fréquence-1|}{(a+b)}$ avec $b > a$.

Pour réaliser la séparation entre hautes et basses fréquences de nos prédictions et de nos images labélisées, nous filtrons nos images à l'aide d'un masque spatial sigmoïde. Nous retrouvons en **Figure 35**, un exemple de séparation de ce filtrage. Une FFT est d'abord appliquée avant le filtrage. On retrouve les résultats de prédiction de fluorescence en **Figure 36**.

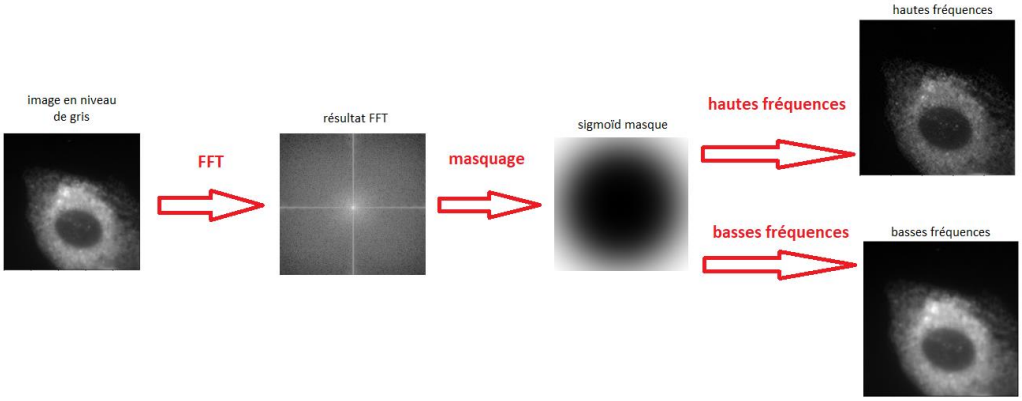
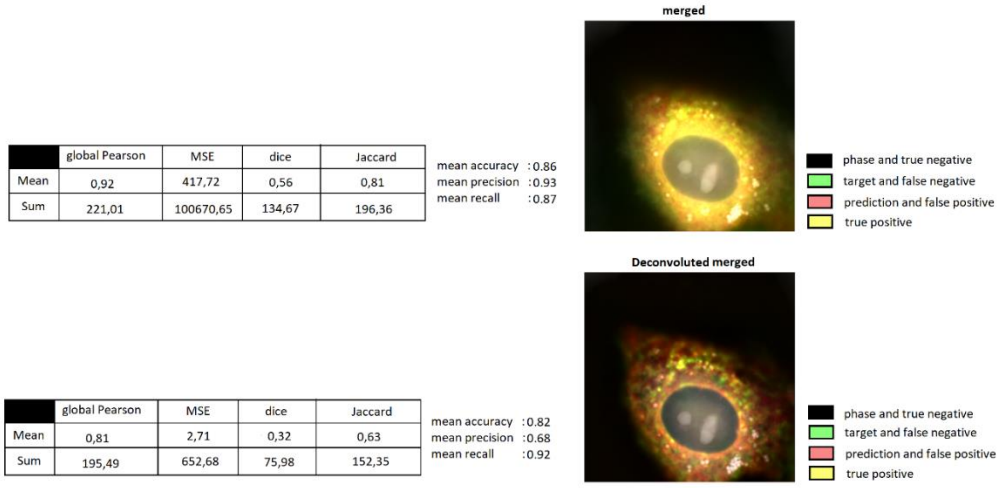


Figure 35 : Opération pour isoler les basses et hautes fréquences



	global Pearson	MSE	dice	Jaccard
Mean	0,92	417,72	0,56	0,81
Sum	221,01	100670,65	134,67	196,36

mean accuracy :0.86
mean precision :0.93
mean recall :0.87

	global Pearson	MSE	dice	Jaccard
Mean	0,81	2,71	0,32	0,63
Sum	195,49	652,68	75,98	152,35

mean accuracy :0.82
mean precision :0.68
mean recall :0.92

Figure 36 : Résultats de prédiction de fluorescence avec la fonction de perte basses et hautes fréquences (rapport de 10 pour 1 entre hautes et basses fréquences)

Notre stratégie pour forcer le modèle à reconstruire les hautes fréquences de nos images n'est pas concluante. Même après avoir rendu les basses fréquences négligeables par rapport aux hautes fréquences (facteur 1 pour 1000), les résultats restent identiques : seules les basses fréquences sont reconstruites.

Les résultats de cette partie peuvent être interprétés comme étant le témoignage d'une limite atteinte. Il est possible que la résolution de notre acquisition ou l'architecture de notre modèle soit limitante pour la prédiction de fluorescence du réticulum endoplasmique. Toutefois la nouvelle fonction de perte peut être utilisée ultérieurement et sa capacité à favoriser les hautes fréquences d'une image pourrais être apprécier dans le futur.

f. Conclusion et perspectives

L'objectif de la mission de prédiction de fluorescence était de réaliser une prédiction de fluorescence d'image de contraste de phase pour prédire une image de fluorescence. Nous avons vu que les prédictions de fluorescence concernant des objets facilement identifiable dont la taille est supérieure à la résolution de nos microscopies, étaient encourageantes. Cependant les composants biologiques dont la taille est plus faible que la résolution et difficilement identifiable produisent des prédictions peu convaincantes : les modèles parviennent alors à reproduire les basses fréquences attendues mais peine à reconstruire les hautes fréquences.

Dans un élan d'optimisation des prédictions, nous avons d'abord tenté de déployer des architectures proches du U Net et avec la particularité de favoriser la conservation d'informations. Ces architectures ont été abandonnées, elles n'apportaient aucune amélioration notable. La mise en place de fonction de perte d'abord basée sur une simple corrélation de Pearson puis sur une corrélation de Pearson appliquée aux basses et hautes fréquences séparément, a permis d'améliorer les prédictions. Cependant à la fin de l'étude une conclusion est émise concernant une possible limite atteinte sur la précision de nos prédictions. Cette limite pourrait être issue de l'architecture U Net ou bien de la résolution de nos acquisitions.

Plusieurs perspectives sont envisageables pour poursuivre l'étude. Nous rappelons que l'acquisition de nos images à contraste de phase ne s'opère pas dans l'ensemble du spectre visible, un filtre est utilisé pour réduire la fluorescence résiduelle. Nous savons aussi que certains composants biologiques ne peuvent être mis en évidence que par l'action de fluorophore spécifique dont le spectre d'émission se situe dans l'infra-rouge. Par conséquent une étude sur l'ensemble du visible étendue aux infra-rouges est une perspective possible. Une autre perspective concerne la résolution de nos microscopes, travailler sur cette résolution pourrait permettre de dépasser cette « limite » déduite. Concernant l'architecture neuronale, l'existant correspond à l'état de l'art actuel cependant les couches convolutionnels et le procédé de rétropropagation du gradient de manière séquentielle, sont des concepts distants du fonctionnement de la vision et de l'apprentissage humain. Nous pourrions imaginer de nouveaux concepts pour les remplacer, l'état de l'art mentionne de nouvelles possibilités pour se soustraire partiellement à la rétropropagation de gradients séquentielle (predictive coding, synthetic gradient). Une autre piste de développement serait de mieux comprendre les opérations effectuées par notre architecture, en d'autres termes réalisés de l'explicative learning. Chacune de ces pistes peut déboucher sur une amélioration de la précision de nos prédictions.

5. Résultats et discussions de la mission de classification

a. Mise en place d'un CNN

Pour la mission de classification, aucun modèle d'apprentissage supervisé n'est déployé. Les données à classés sont des images. Puisque les modèles convolutionnels offrent de bons résultats sur la classification d'images tout en assurant l'extraction de descripteurs, nous choisissons de réaliser un réseau de neurones convolutionnels. En **Figure 37**, un schéma du réseau déployé est visible. Les images en entrées sont prétraitées avec l'égalisation d'ordre de grandeur intensité/phase. Les couches convolutionnels du réseau extraient les descripteurs de l'image par compression de l'information. Les dernières couches linéaires assurent l'opération de classification.

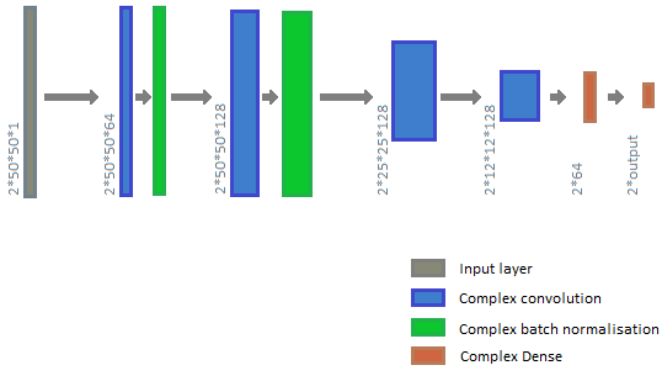
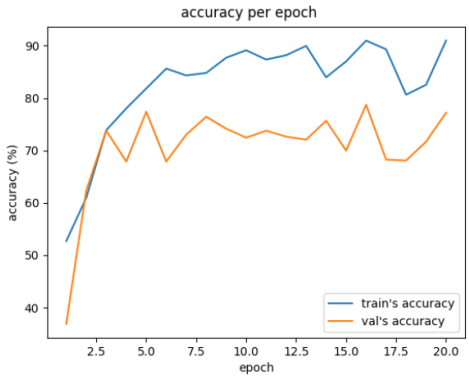
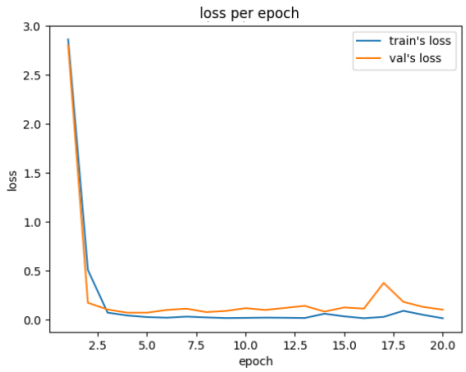


Figure 37 : Schéma du réseau de neurones convolutionnels

En **Figure 38**, nous retrouvons le résultat d'entrainement et de classification pour notre modèle convolutionnels. La précision sur la classification atteint les 75%, il ne semble pas y avoir de sur-apprentissage ou de sous-apprentissage dans l'entrainement. Néanmoins nous constatons grâce à la matrice de confusion que notre modèle à des difficultés dans la classification de certaines classes. Notre jeu est constitué de nanoparticules de taille et nature différentes, nous avons des nanoparticules de polystyrènes (PS), des nanoparticules métalliques (Ag, Au) et des nanoparticules virales. Les erreurs de classifications concernent majoritairement les nanoparticules virales. Pour notre étude l'expertise terrain nous révèle que les nanoparticules métalliques sont facilement identifiables, les nanoparticules de polymères sont plus difficilement classifiables et les nanoparticules virales sont difficilement dissociables. Notre modèle est en adéquation avec la vérité-terrain : il peine à dissocier les nanoparticules virales.





confusion matrix

	Ag100	Au100	Au60	HIV DeltaEnv	HIV EVs	HIV WT	PS100	PS200	SARS CoV 2	Si100	Si150	VLP GAG	VLP GAG RNA
Ag100	158	0	0	0	0	0	0	0	0	0	0	0	0
Au100	1	163	0	0	0	0	0	0	0	0	0	0	0
Au60	0	0	155	0	0	0	0	0	0	0	0	0	0
HIV DeltaEnv	0	0	1	38	0	3	0	0	0	0	0	0	0
HIV EVs	0	0	1	1	221	3	1	3	0	0	6	0	4
HIV WT	0	0	4	81	5	264	15	0	13	0	8	5	23
PS100	0	0	0	4	0	2	185	0	0	1	2	0	0
PS200	0	1	0	0	0	0	0	171	0	0	0	0	0
SARS CoV 2	0	0	0	0	0	0	3	0	31	0	0	0	1
Si100	0	0	1	1	0	0	3	0	4	86	1	0	0
Si150	0	0	0	1	2	0	1	0	0	0	309	1	2
VLP GAG	0	0	1	1	1	5	1	0	24	1	0	72	10
VLP GAG RNA	0	0	0	0	2	1	0	0	0	0	0	0	100

Figure 38 : Résultats d'entrainement et de classification pour le CNN

Dans cette partie nous avons tenté de classer nos individus à partir des images de notre jeu de données labélisé. Les classifications à partir des images est de bonne qualité néanmoins pour notre étude nous disposons aussi de trois variables extraites lors du prétraitement. Il est possible que l'exploitation de ces variables soit suffisante à elle seule pour la classification.

b. Mise en place d'un réseau de neurones linéaire

Afin d'exploiter les variables disponibles dans le jeu de données. Nous mettons en place un nouveau réseau de neurones, ce réseau est constitué uniquement de couches convolutionnels. Nous retrouvons en **Figure 39**, un schéma du réseau linéaire déployé. L'ambition de ce nouveau réseau est de surpasser la précision de 75% du réseau convolutionnels. L'existant pour cette mission, utilise ces 3 variables dans les modèles non supervisés.

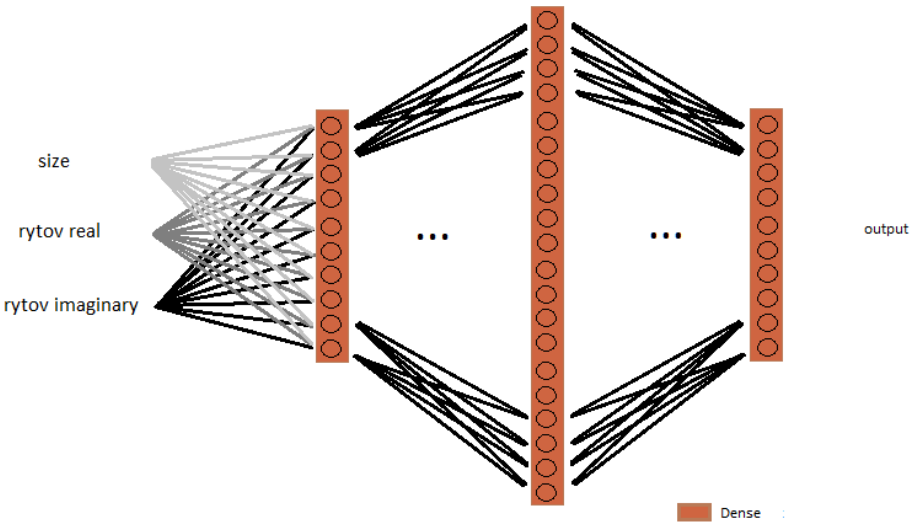


Figure 39 : Schéma du réseau de neurones linéaire

Les résultats d'entrainement et de classification sont observables en **Figure 40**. Nous constatons que ces résultats sont de mauvaise qualité. Nous rappelons que la superposition concernant ces variables est importante et qu'il est donc difficile pour un réseau de neurones linéaires de trouver des frontières acceptables pour chaque classe, une amélioration possible pourrait être de regrouper certaines classes entre elles afin de former des macros-classes dont les frontières seraient plus facilement identifiables. Pour notre étude aucune contrainte particulière n'est attendue sur la classification, nous souhaitons seulement explorer les possibilités. Aussi l'usage de macro-classes est un scénario envisageable.

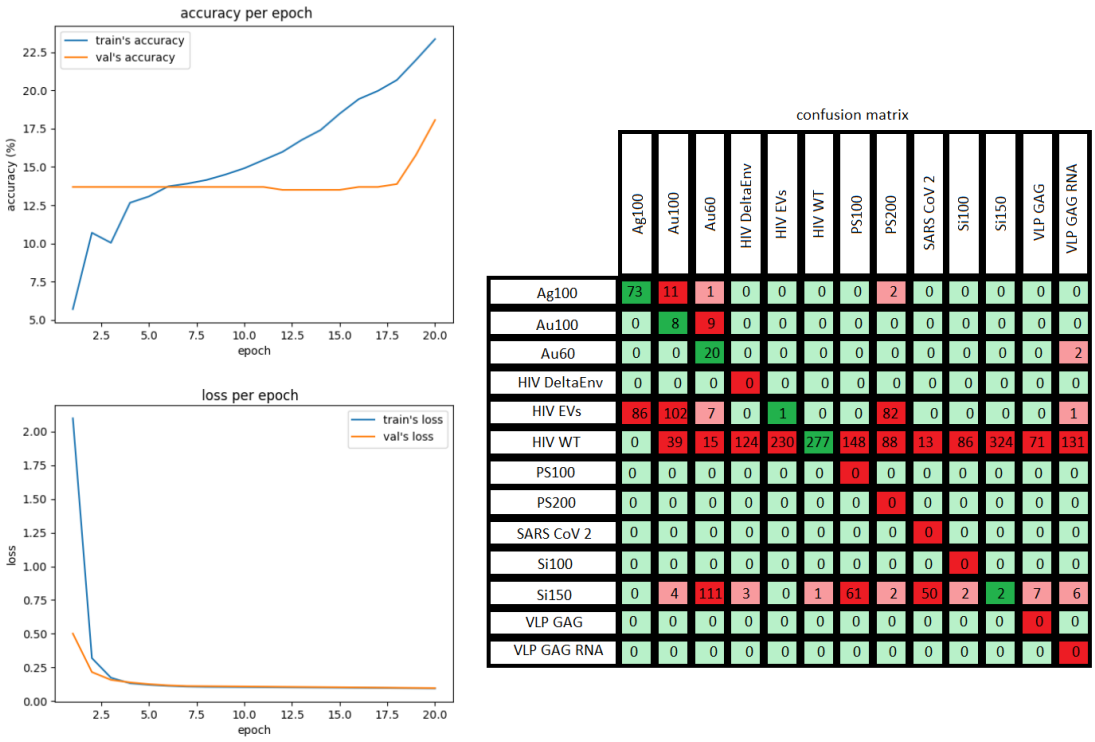


Figure 40 : Résultats d'entrainement et de classification pour le réseau linéaire

Les variables seules produisent une classification aléatoire. Le dimensionnement du modèle linéaire est peut-être la cause de ce résultat. La superposition des variables est aussi un facteur aggravant. Cependant nous savons que ces variables sont directement liées à la nature de nos nanoparticules. Il est intéressant de pouvoir exploiter ces variables dans notre étude.

c. Seconde version du CNN : réseau de neurone hybride

Pour utiliser les variables associées aux images, nous mettons en place un modèle hybride capable de recevoir ces deux entrées. Le schéma du modèle est disponible en **Figure 41**. Nous choisissons d'utiliser uniquement la variable taille. Les deux autres variables sont moins interprétables que la taille.

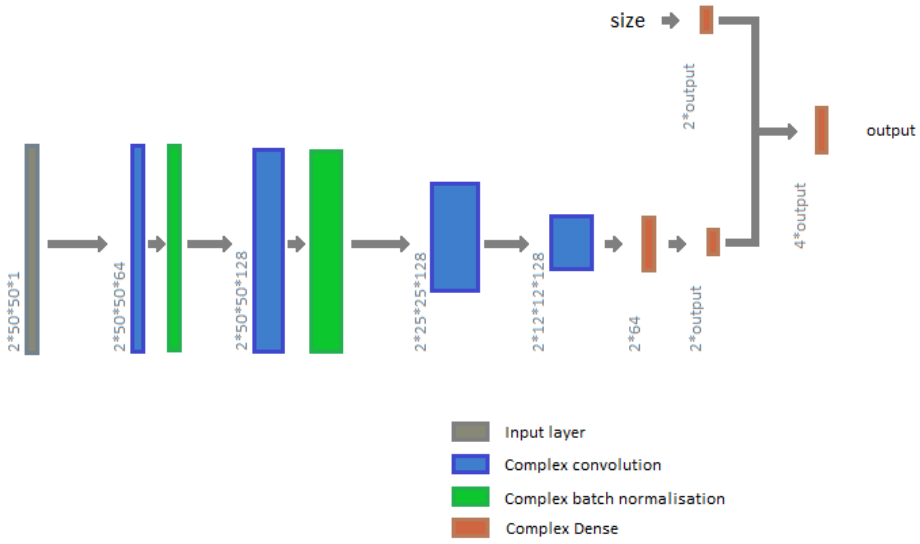
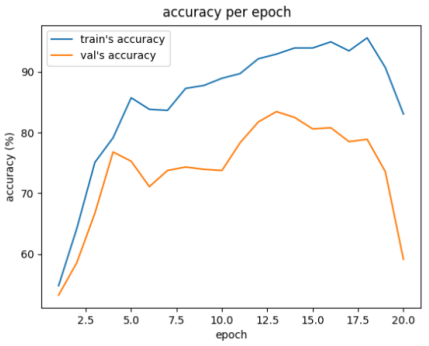
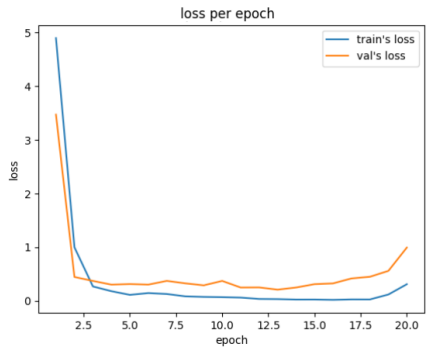


Figure 41 : Schéma du réseau de neurone hybride

En **Figure 42**, nous observons les résultats de classification de notre modèle hybride. On observe un sur-apprentissage à partir de l'époque d'entrainement 16. La précision de classification avant l'époque 16 était aux alentours de 80%. Après avoir réalisé de multiples entrainements, cette précision de 80% s'avère être la précision moyenne atteinte par notre modèle hybride. La matrice de confusion est obtenue après l'ensemble des époques d'entrainement, par conséquent elle indique uniquement la classe sur-apprise, il semblerait que cette classe soit « HIV WT ».





confusion matrix

	Ag100	Au100	Au60	HIV DeltaEnv	HIV EVs	HIV WT	PS100	PS200	SARS CoV 2	Si100	Si150	VLP GAG	VLP GAG RNA
Ag100	158	3	1	0	2	0	0	1	0	1	0	0	3
Au100	1	160	6	0	0	0	0	20	0	0	0	0	0
Au60	0	0	106	0	0	0	0	0	0	0	0	0	0
HIV DeltaEnv	0	0	4	64	0	15	26	0	8	12	2	1	0
HIV EVs	0	1	2	0	136	0	0	4	0	0	3	0	5
HIV WT	0	0	8	62	45	262	68	0	9	43	101	44	93
PS100	0	0	28	1	0	0	96	0	0	0	0	0	0
PS200	0	0	1	0	34	0	2	147	0	0	1	0	1
SARS CoV 2	0	0	1	0	0	0	5	0	55	0	0	2	0
Si100	0	0	0	0	0	0	1	0	0	219	0	0	0
Si150	0	0	5	0	11	1	9	0	0	0	219	0	9
VLP GAG	0	0	1	0	1	0	2	0	0	5	0	29	3
VLP GAG RNA	0	0	0	0	2	0	0	2	0	0	0	2	26

Figure 42 : Résultats d'entrainement et de classification pour l'hybride

Nos modèles fournissent des prédictions qui laissent une marge de progression importante. Pour améliorer notre classification nous devons trouver le moyen de favoriser la variance inter-cluster. L'utilisation de macro-classes pourrait permettre de favoriser cette variance.

d. Macro-classes et coopérations de modèles

Notre dernier modèle utilise des macros-classes, les métaux, les polymères et les nanoparticules virales sont regroupées ensemble. Nous faisons le choix de n'utiliser que les classes dont la proportion d'individus est suffisante et avec une proportion d'outliers réduit. Les classes « VLP GAG » et « VLP GAG RNA sont retirées du jeu de données pour cette partie. Afin de maximiser nos chances, nous concentrons nos efforts sur la nature seule des nanoparticules ainsi les classes « PS100 » et « PS200 » sont regroupées en une seule classe « PS », de même pour « Si » et « Au ». Concernant les virus, la classe « HIV DeltaEnv » et la classe « HIV WT » sont regroupées, ces deux classes correspondent aux particules virales du VIH mature (pour « HIV WT ») et non mature (« HIV DeltaEnv »). Le regroupement viral est motivée par la présence non négligeable (environ 20%) de particules virales matures parmi les particules virales labélisées comme non mature.

Notre nouveau modèle est en réalité un environnement constitué de 4 modèles fonctionnant ensemble. Cet environnement est schématisé en **Figure 43**. Le premier modèle est un modèle convolutionnels classique, son schéma est visible en partie 5.a. Les 3 modèles suivants peuvent être de la même nature que le premier ou bien ils peuvent être hybrides. Le premier modèle permet de classer nos individus selon les macros-classes. Les modèles suivants réalisent une classification plus fine afin de retrouver la nature des nanoparticules.

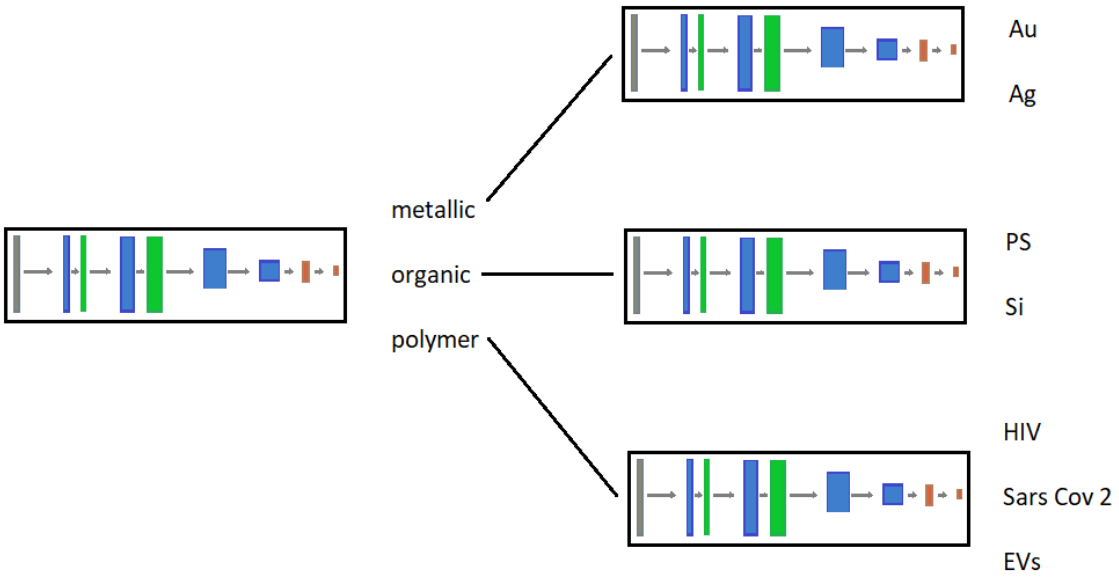
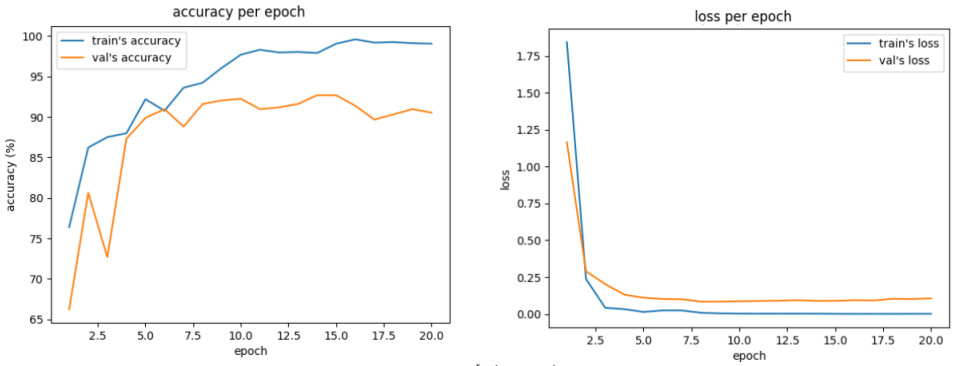


Figure 43 : Schéma de la coopération de modèles

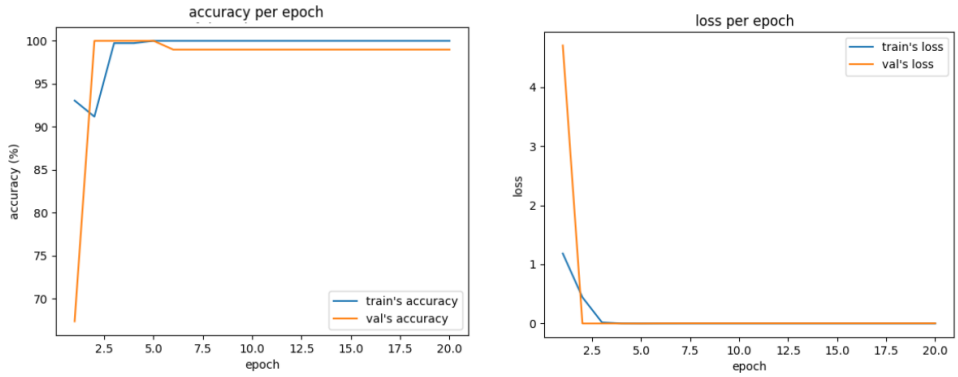
Les **Figures 44 à 47** présentent les résultats d'entrainement pour nos modèles. Ces résultats correspondent à un entrainement sur des modèles non hybrides. Nous constatons que la précision du premier modèle visant à classifier notre jeu selon les macros-classes obtient une précision de 90%, ce résultat est réplicable. Pour les macros-classes les erreurs de classifications concernent les virus et les polymères. Pour la classification fine, le modèle en charge de la classification des métaux à une précision supérieure à 95%. Le modèle en charge de la classification des virus a une précision de 80%. Après avoir répété les entrainements, les erreurs principales concernent la classification de « SARS CoV 2 » et de « HIV EVs ». Le modèle en charge de la classification des polymères à une précision de 85%, ces principales erreurs concernent la classification du polystyrène confondue avec le silicium. Un environnement constitué de modèle hybride offre des résultats semblables.



confusion matrix

	metal	organic	polymer
metal	471	1	2
organic	0	545	21
polymer	1	43	855

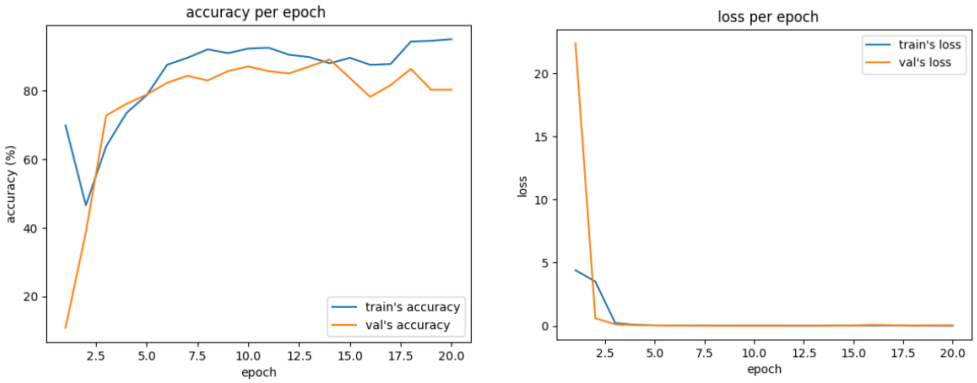
Figure 44 : Résultats pour la coopération (macro-classes)



confusion matrix

	Ag	Au
Ag	152	0
Au	1	319

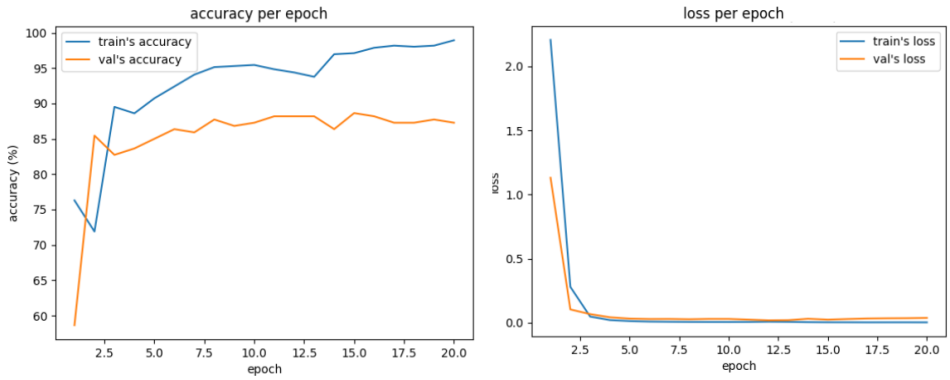
Figure 45 : Résultats pour la coopération (métaux)



confusion matrix

	HIV EVs	HIV WT	SARS CoV 2
HIV EVs	173	0	0
HIV WT	59	279	7
SARS CoV 2	0	7	64

Figure 46 : Résultats pour la coopération (virus)



confusion matrix

	PS	Si
PS	402	3
Si	59	414

Figure 47 : Résultats pour la coopération (polymères)

L'environnement déployé permet de surpasser la précision des modèles précédents. Cependant ces nouveaux résultats sont obtenus en sacrifiant la classification selon la taille, en factorisant deux classes du même virus à un stade de maturité variable et en supprimant deux classes minoritaires.

e. Conclusion et perspectives

L'objectif de la mission de classification était de parvenir à labéliser des nanoparticules de nature inconnues. Seuls des modèles dit non supervisés été en place au début de la mission. Les résultats permettaient alors de classifier aisément un nombre réduit de classes présentant une variance inter-cluster importante. L'ambition de la mission était de déployer des modèles d'apprentissage machine supervisé pour réaliser une classification plus fine y compris sur les classes plus problématiques.

Pour parvenir à réaliser la classification, plusieurs modèles ont été conçus. D'abord un réseau de neurones convolutionnels pour réaliser une extraction de descripteurs de manière automatique sur nos images et les classer selon ces descripteurs. Ce premier modèle a montré des faiblesses dans la classification des nanoparticules virales cependant sa précision de classification est importante. Le second modèle, linéaire et se basant sur 3 variables disponibles dans le jeu de données d'entrainement a fourni des résultats aléatoires. Le troisième modèle déployé, un modèle hybride utilisant les images et l'une des variables disponibles dans notre jeu de données a permis de surpasser la précision du premier modèle. Motivé par un besoin de classer au mieux l'ensemble des nanoparticules y compris les virales, un environnement constitué de 4 modèles a été imaginé. Cet environnement a produit une classification de qualité mais au détriment de la diversité des classes. Aussi nous devons rester critique sur les résultats de l'entrainement. La **Figure 48** nous présente le résultat de classification sur deux jeux de données mixtes. Chacun de ces jeux est en réalité constitué de nanoparticules d'or et de polystyrènes, en proportion équiprobable, cependant la labélisation réelle est inconnue. On constate que la classification réalisée par notre environnement de 4 modèles échoue en partie pour ces deux jeux mixtes. Il est possible que le jeu de données soit insuffisant et ne capture pas l'ensemble des variations possibles pour nos classes.

	jeu de données mixtes 1 (PS, Au)		jeu de données mixtes 2 (PS, Au)	
	modèle coopératif utilisant des réseaux convolutionnels hybrides	modèle coopératif utilisant des réseaux convolutionnels classiques	modèle coopératif utilisant des réseaux convolutionnels hybrides	modèle coopératif utilisant des réseaux convolutionnels classiques
metaux	42,53%		62,30%	
Ag	0,00%	0,00%	0,00%	0,00%
Au	100,00%	100,00%	100,00%	100,00%
polymères	44,83%		5,46%	
PS	73,08%	66,67%	90,00%	0,00%
Si	26,92%	33,33%	10,00%	100,00%
Virus	12,64%		32,24%	
HIV Evs	0,00%	9,09%	38,98%	38,98%
HIV WT	45,45%	68,18%	61,02%	61,02%
SARS CoV 2	54,55%	22,73%	0,00%	0,00%

Figure 48 : classification par le modèle coopératif sur les jeux de données mixtes

Plusieurs perspectives sont envisageables pour améliorer notre classification sans contraindre le nombre de clusters. Nous savons que le jeu actuel est un jeu comprenant aux alentours de 2000 individus, aussi la stratification de ce jeu de données n'est pas propice à un apprentissage. La **Figure 49,** nous montre la stratification actuelle de notre jeu de données : les classes ne sont pas équiprobables dans notre jeu de données. Une première voie d'améliorations serait donc d'augmenter le nombre d'individus de notre jeu de données et de rendre chaque classe équiprobable au sein de ce jeu. L'acquisition ou la *data augmentation* sont deux possibilités.

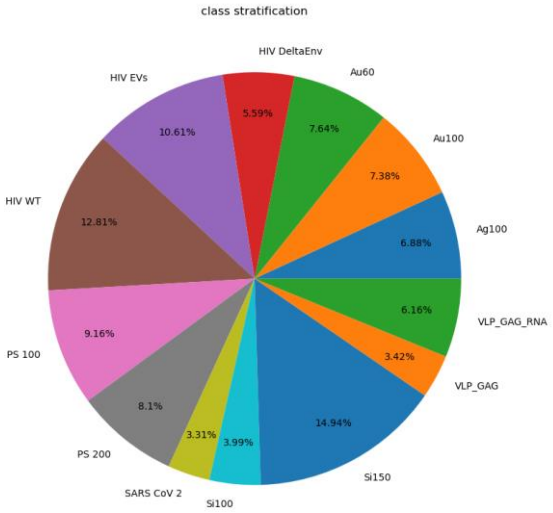


Figure 49 : stratification de notre jeu labélisé

Conclusion

L'objectif de nos missions était de réaliser une prédiction de fluorescence d'image de contraste de phase pour retrouver les informations mit en évidence par une image de fluorescence et réaliser une classification d'image à contraste de phase de nanoparticules pour identifier la nature de ces dernières. L'objectif des missions a était atteint. Cependant, concernant la mission de prédiction de fluorescence, les scénarios de prédiction de fluorescence de réticulum endoplasmique restent difficilement exploitables par les biologistes. Concernant la mission de classification, un individu singulier par rapport au jeu d'entrainement génèrera une classification erronée. Pour la mission de prédiction de fluorescence, la reproduction des hautes fréquences de nos réticulums endoplasmiques échoue avec comme causes potentielles une résolution d'acquisition insuffisante et/ou un dimensionnement de modèle insuffisant. Pour la mission de classification, la cause d'une classification erronée semble être la faible variabilité du jeu d'entrainement ainsi que la taille de ce jeu de données et sa stratification.

Ma conclusion personnelle sur ce stage est positive. La montée en compétence et le gain d'autonomie sur un projet complet son deux points plaisants. J'ai appris plusieurs choses très intéressantes et parfois même hors de mon champ de compétences initiales : optique, culture cellulaire, bonne pratique informatique, *deep learning*, … Les points les plus compliqués pour moi ont étaient la proportion occupée par le code et la frustration de la recherche. Désormais je sais qu'il me faut diversifier la nature de mes missions. Concernant la frustration de la recherche, cette dernière est vite apaisée par des résultats prometteurs et parfois inattendus.

Bibliographie

[1] C. Ounkomol, S. Seshamani, M. M. Maleckar, F. Collman, et G. R. Johnson, « Label-free prediction of three-dimensional fluorescence images from transmitted-light microscopy », *Nat. Methods*, vol. 15, n° 11, p. 917-920, nov. 2018, doi: 10.1038/s41592-018-0111-2.

[2] E. M. Christiansen, S. J. Yang, et L. L. Rubin, « In Silico Labeling: Predicting Fluorescent Labels in Unlabeled Images | Elsevier Enhanced Reader », doi: 10.1016/j.cell.2018.03.040.

[3] P. Bon, G. Maucort, B. Wattellier, et S. Monneret, « Quadriwave lateral shearing interferometry for quantitative phase microscopy of living cells », *Opt. Express*, vol. 17, n° 15, p. 13080, juill. 2009, doi: 10.1364/OE.17.013080.

[4] C. Trabelsi *et al.*, « DEEP COMPLEX NETWORKS », p. 19, 2018.

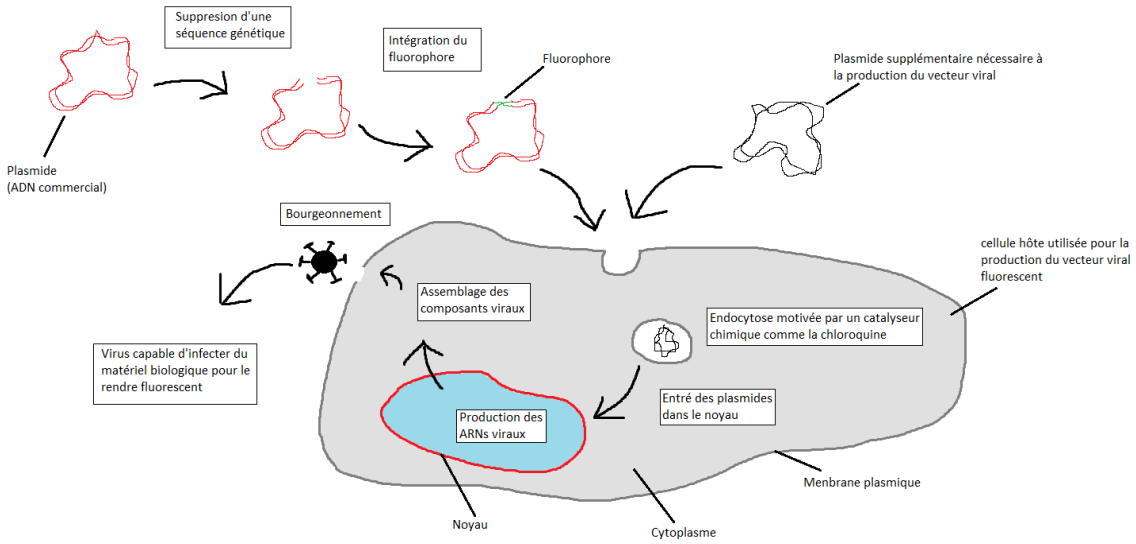
[5] O. Ronneberger, P. Fischer, et T. Brox, « U-Net: Convolutional Networks for Biomedical Image Segmentation », *ArXiv150504597 Cs*, mai 2015, Consulté le: 7 avril 2022. [En ligne]. Disponible sur: http://arxiv.org/abs/1505.04597

[6] R. Mehta et J. Sivaswamy, « M-net: A Convolutional Neural Network for deep brain structure segmentation », *2017 IEEE 14th Int. Symp. Biomed. Imaging ISBI 2017*, p. 437-440, avr. 2017, doi: 10.1109/ISBI.2017.7950555.

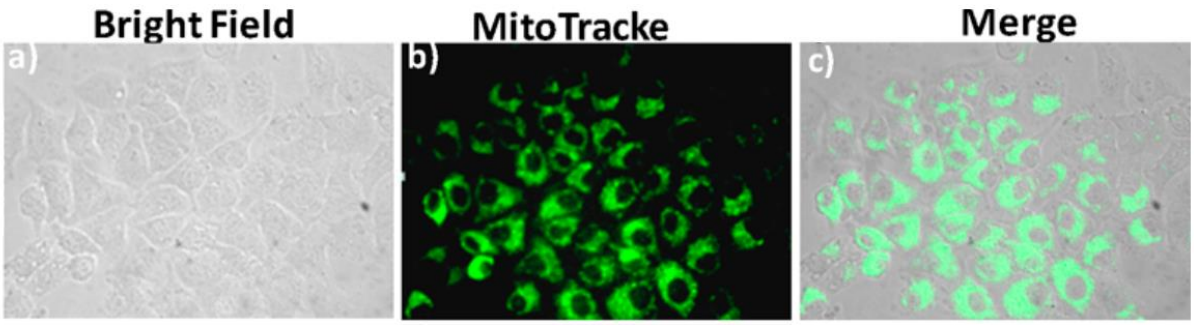
[7] N. Ibtehaz et M. S. Rahman, « MultiResUNet : Rethinking the U-Net Architecture for Multimodal Biomedical Image Segmentation », *Neural Netw.*, vol. 121, p. 74-87, janv. 2020, doi: 10.1016/j.neunet.2019.08.025.

Annexes 1 : Marquage fluorescent

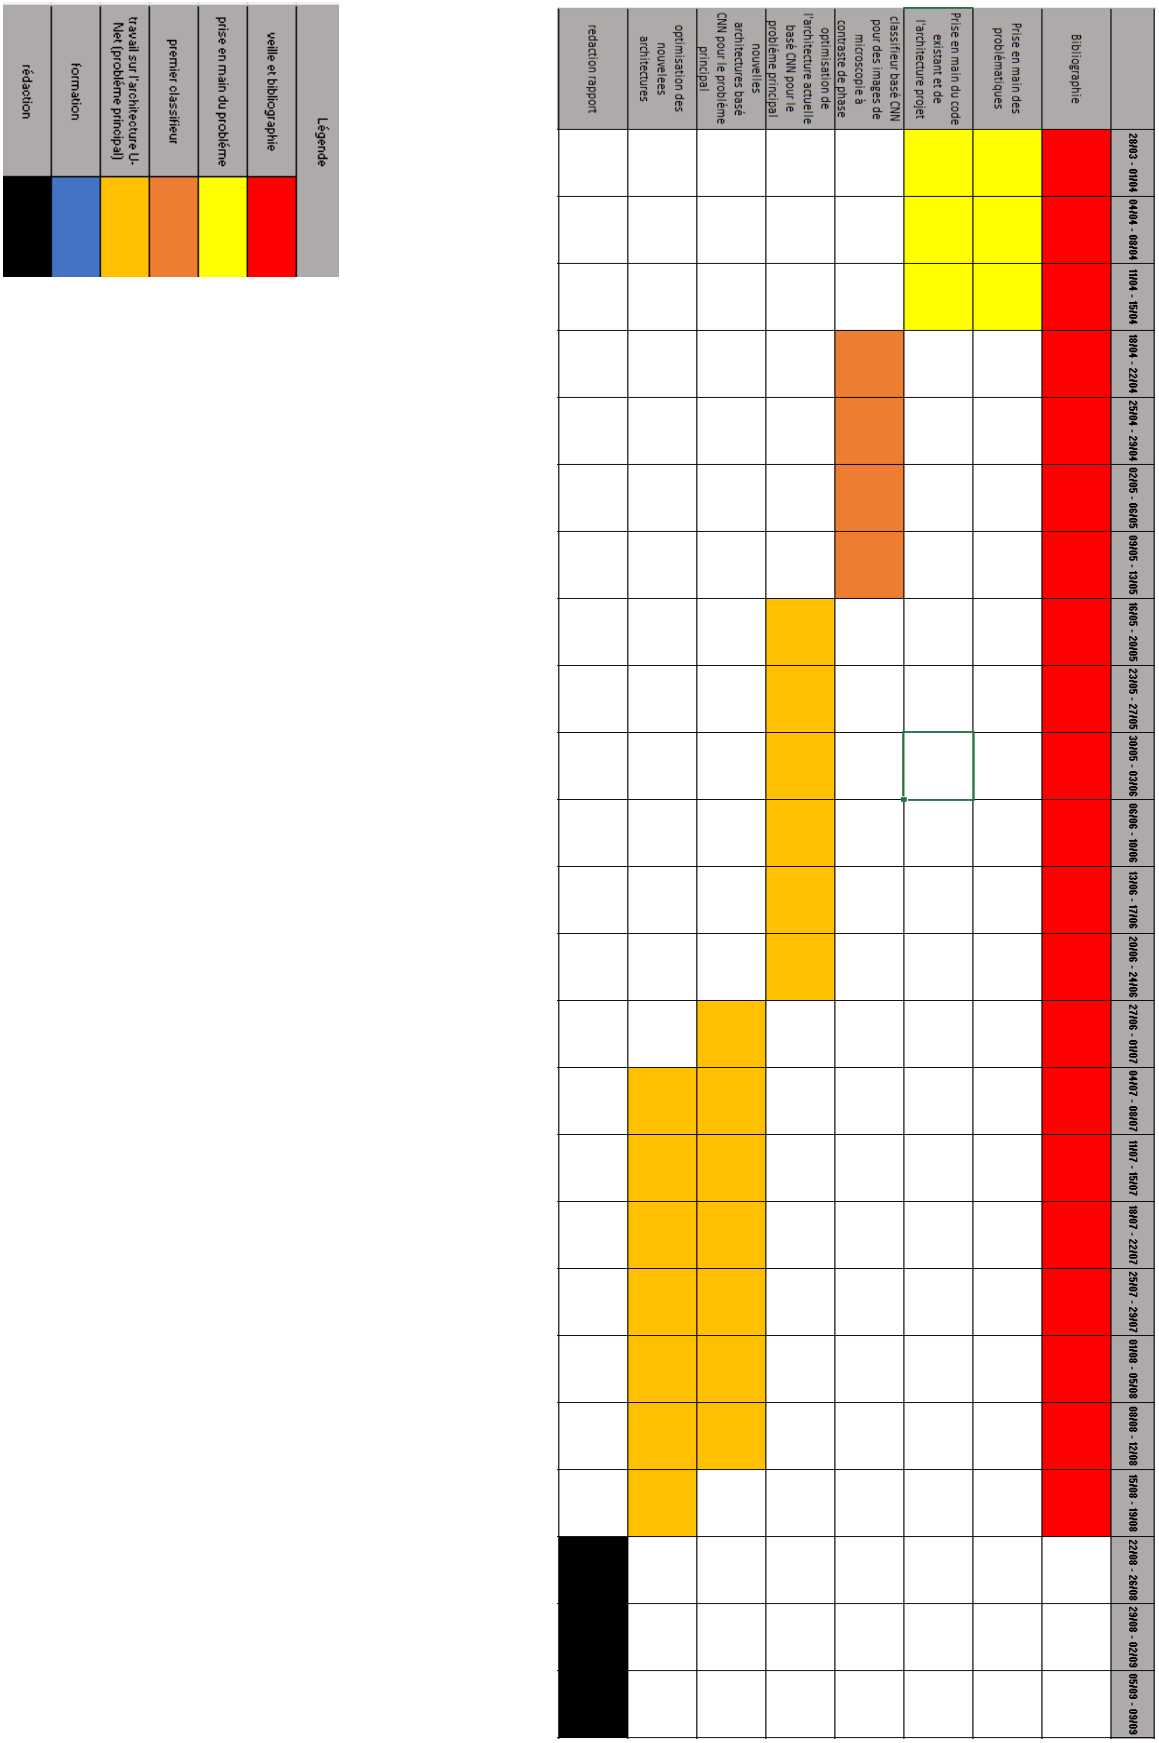
Sur la figure suivante, Nous observons le schéma illustrant le procédé de fabrication des virus capable d'infecter les matériels biologiques pour les rendre fluorescents. Une cellule hôte est utilisée pour assembler différents plasmides (ADN circulaire) codant la fabrication du virus : Un de ces plasmides est modifié pour embarquer le fluorophore.



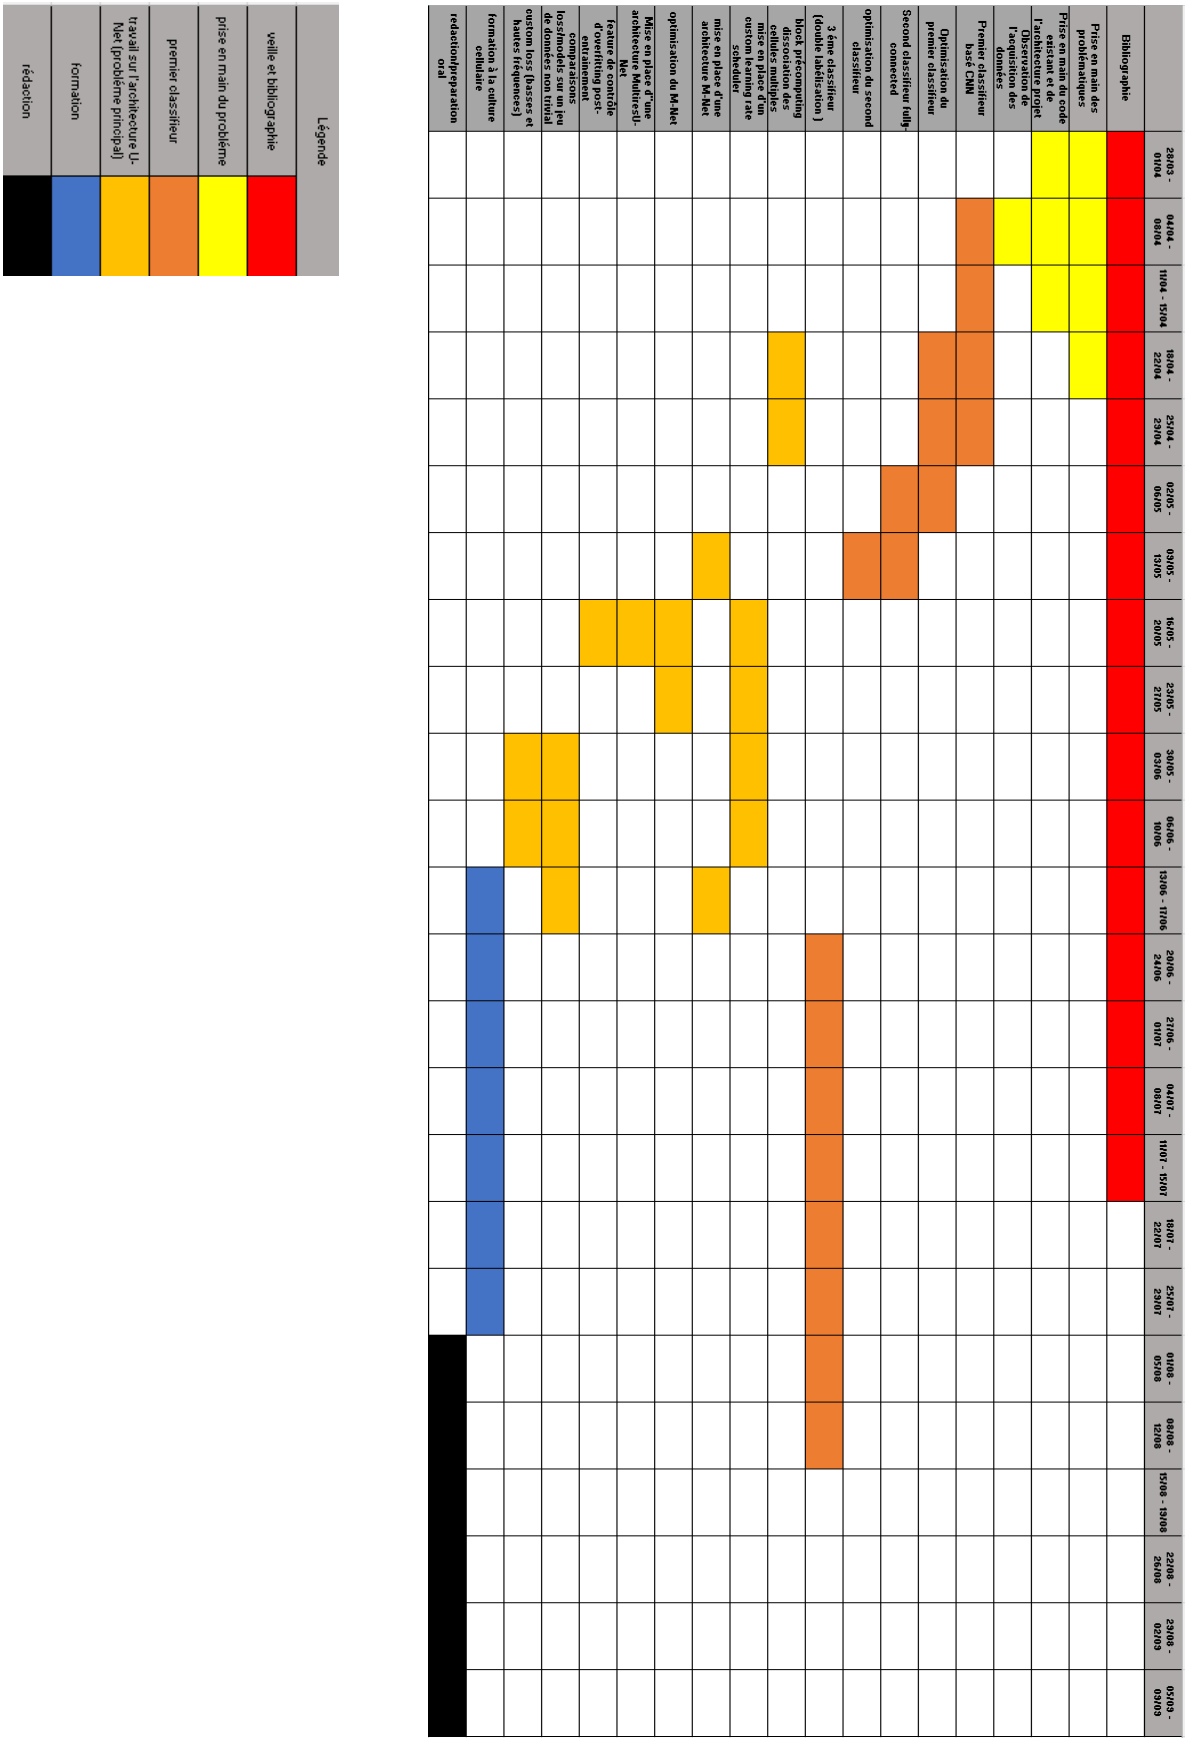
Un fois que le vecteur viral est créé, il nous suffit de le titrer avant de pouvoir l'utiliser. Nous cherchons alors le MOI ou *Multiplicity of Infection*. Cette titration nous permettra de mélanger la quantité de virus adéquate avec notre échantillon. Sur la figure suivante, nous constatons un titrage, Ici le M.O.I est de 100% puisque toutes les cellules expriment la fluorescence : c'est donc la quantité virale de référence qu'il faudra utiliser pour infectée de nouveaux échantillons.



Annexes 2 : Gestion du temps, Gantt prévu



Annexes 3 : Gestion du temps, Gantt réel



Résumé :

Venez découvrir, dans ce rapport, une méthode pour étendre votre vision. Observer le monde cellulaire devient moins houleux et plus intuitif. Ce rapport vous présentera un procédé alliant apprentissage supervisé profond et imagerie par microscopie. La microscopie de fluorescence contraignante et invasive tend à être secondée par ce concept. Une illumination blanche simple, un réseau de neurones entrainé et un microscope à contraste de phase sont aujourd'hui capables d'approcher de la précision d'une microscopie de fluorescence. En plus de favoriser une observation naturelle, vous pourrez réaliser des économies sur les coûts de fabrication des échantillons. Vous découvrirez aussi que l'association acquisition à contraste de phase et apprentissage supervisé peut vous aider à classifier un ensemble de nano éléments. Les résultats de ce rapport permettent de se projeter et d'imaginer une extension aux techniques de microscopies actuelles.

Resume :

In this report, you will discover a method to extend your vision. Observing the cellular world becomes less stormy and more intuitive. This report will introduce you, a process combining deep supervised learning and microscopic imaging. Constraining and invasive fluorescence microscopy tends to be supported by this concept. Simple white illumination, a trained neural network and a phase contrast microscope are now able to approach the precision of classic fluorescence microscopy. In addition to promoting natural observation, you can reduce the costs of manufacturing samples. You would also find that the combination of phase contrast acquisition and supervised learning can help you classify a set of nano elements. The results of this report allow us to project and imagine an extension to current microscopy techniques.